

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

**Hệ thống phát hiện và nhận dạng biển số xe chuyển
động trong các nguồn video**

LÊ VIỆT ANH

anh.lv225250@sis.hust.edu.vn

Chương trình đào tạo: Kỹ thuật máy tính

Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Hoàng Lan

Khoa: Kỹ thuật máy tính

Trường: Công nghệ thông tin và Truyền thông

HÀ NỘI, 06/2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

**Hệ thống phát hiện và nhận dạng biển số xe chuyển
động trong các nguồn video**

LÊ VIỆT ANH

anh.lv225250@sis.hust.edu.vn

Chương trình đào tạo: Kỹ thuật máy tính

Giảng viên hướng dẫn: PGS. TS. Nguyễn Thị Hoàng Lan

Chữ kí GVHD

Khoa: Kỹ thuật máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2026

LỜI CẢM ƠN

Đồ án tốt nghiệp này là kết quả của một hành trình dài với không ít khó khăn và thử thách. Để hoàn thành được công trình này, tôi đã nhận được sự hỗ trợ và động viên từ nhiều người mà tôi muốn bày tỏ lòng biết ơn chân thành.

Trước tiên, tôi xin gửi lời cảm ơn sâu sắc đến PGS.TS. Nguyễn Thị Hoàng Lan — người đã tận tình hướng dẫn, góp ý và định hướng cho tôi trong suốt quá trình thực hiện đồ án. Những nhận xét thẳng thắn và sự kiên nhẫn của cô đã giúp tôi nhìn rõ hơn những điểm còn thiếu sót và không ngừng cải thiện chất lượng công việc.

Tôi cũng xin cảm ơn gia đình đã luôn là chỗ dựa vững chắc, động viên tôi những lúc nản lòng và tạo điều kiện tốt nhất để tôi có thể tập trung học tập.

Cảm ơn những người bạn đã cùng trao đổi, chia sẻ kinh nghiệm và tiếp thêm năng lượng trong những giai đoạn căng thẳng nhất của quá trình làm đồ án.

Cuối cùng, tôi muốn nhìn lại bản thân mình với một chút tự hào — vì đã không bỏ cuộc, đã chọn làm kỹ hơn thay vì làm xong cho xong, và đã cố gắng đến cùng để hoàn thành đồ án này một cách tốt nhất có thể.

TÓM TẮT NỘI DUNG ĐỒ ÁN

Nhận dạng biển số xe tự động (Automatic License Plate Recognition — ALPR) là thành phần cốt lõi trong các hệ thống giao thông thông minh, được ứng dụng rộng rãi trong giám sát an ninh, xử lý vi phạm và thu phí tự động. Phần lớn các giải pháp hiện nay được thiết kế cho môi trường có kiểm soát, nơi camera đặt cố định, phương tiện di chuyển chậm và ánh sáng đồng đều. Khi triển khai vào môi trường thực tế không ràng buộc — chẳng hạn camera giám sát tại ngã tư hay camera hành trình — hiệu năng của các hệ thống này suy giảm đáng kể do biển số liên tục bị mờ nhòe, lóa sáng, thay đổi góc nhìn và độ phân giải thấp. Một hạn chế phổ biến của các giải pháp học sâu hiện hành là tiếp cận bài toán theo hướng nhận dạng đơn khung hình, bỏ qua ngữ cảnh thời gian trong luồng video; điều này dẫn đến kết quả không ổn định khi chất lượng từng khung hình dao động lớn.

Đồ án này lựa chọn hướng tiếp cận xử lý video theo quỹ đạo phương tiện thay vì nhận dạng độc lập từng khung hình, xuất phát từ quan sát rằng dù mỗi khung hình riêng lẻ có thể bị nhiễu, chuỗi video vẫn chứa đủ thông tin dư thừa theo thời gian để suy ra biển số chính xác nếu có cơ chế tổng hợp phù hợp.

Giải pháp đề xuất là một pipeline đa tầng gồm: phát hiện phương tiện bằng YOLOv5, theo dõi đa đối tượng bằng BoT-SORT, phát hiện biển số bằng YOLOv8-OBB với đầu ra hộp bao có hướng, phân loại chất lượng crop biển số bằng một bộ định tuyến (Quality Router) để phân luồng xử lý, nhận dạng ký tự bằng mô hình OCR SmallLPR-Line-CTC được thiết kế riêng cho biển số Việt Nam một và hai dòng, và cuối cùng tổng hợp kết quả từ nhiều khung hình trong cùng một track bằng cơ chế Character Time-series Matching kết hợp bỏ phiếu theo vị trí ký tự.

Các đóng góp chính của đồ án gồm: xây dựng bộ dữ liệu đa nhiệm với hơn 40.000 ảnh nhãn OBB và hơn 33.000 ảnh crop biển số; thiết kế kiến trúc SmallLPR-Line-CTC với STN alignment, MixConv, CBAM và multi-head CTC theo bố cục dòng; và triển khai hệ thống web end-to-end hỗ trợ xử lý video tải lên và luồng RTSP. Kết quả thực nghiệm cho thấy mô hình OCR đạt exact-match accuracy 95,01%, detector biển số đạt mAP@0.5 bằng 0,983, và pipeline tổng thể nhận dạng đúng 79 trên 88 biển số quan sát được trên ba nhóm kịch bản thử nghiệm thực tế.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Đặt vấn đề.....	1
1.2 Các giải pháp hiện tại và hạn chế	2
1.3 Mục tiêu và định hướng giải pháp	3
1.4 Đóng góp của đề án	3
1.5 Bố cục đề án	4
CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT	5
2.1 Ngữ cảnh bài toán.....	5
2.2 Các nghiên cứu tương tự.....	6
2.3 Các mô hình phát hiện đối tượng.....	7
2.3.1 YOLOv5	7
2.3.2 YOLOv8 OBB	8
2.4 Các thuật toán truy vết đối tượng.....	10
2.4.1 BoT-SORT	10
2.5 Các mô hình nhận diện kí tự quang học (OCR).....	12
2.5.1 Các phương pháp nhận dạng phân đoạn ký tự	12
2.5.2 Các phương pháp nhận dạng không phân đoạn ký tự	14
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT.....	17
3.1 Tổng quan giải pháp.....	17
3.2 Thu thập và xử lí dữ liệu.....	18
3.2.1 Dữ liệu phát hiện biển số	18
3.2.2 Dữ liệu nhận diện biển số.....	19
3.2.3 Dữ liệu đánh giá chất lượng biển số	20

3.3 Huấn luyện mô hình.....	21
3.3.1 Mô hình nhận diện phương tiện	21
3.3.2 Mô hình nhận diện biển số	21
3.3.3 Thuật toán tracking	22
3.3.4 Mô hình phân loại chất lượng	23
3.3.5 Kiến trúc và huấn luyện mô hình OCR (SmallLPR-Line-CTC).....	25
3.4 Xử lý kết quả sau mô hình	31
3.4.1 Xác thực định dạng biển số	32
3.4.2 Tổng hợp đa khung hình	33
CHƯƠNG 4. XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG.....	35
4.1 Yêu cầu và kiến trúc tổng quan	35
4.1.1 Sơ đồ use case	35
4.1.2 Thiết kế kiến trúc	36
4.2 Xây dựng ứng dụng.....	38
4.2.1 Công nghệ sử dụng.....	38
4.2.2 Frontend.....	40
4.2.3 Backend	41
4.2.4 Thiết kế cơ sở dữ liệu	43
4.3 Triển khai	45
CHƯƠNG 5. ĐÁNH GIÁ THỰC NGHIỆM.....	47
5.1 Môi trường và tiêu chí đánh giá.....	47
5.2 Kết quả các mô hình thành phần.....	48
5.2.1 Mô hình phát hiện phương tiện	48
5.2.2 Mô hình phát hiện biển số.....	48
5.2.3 Kết quả huấn luyện mô hình Quality Router	49
5.2.4 Mô hình OCR.....	50

5.2.5 Ablation study mô hình OCR	50
5.3 Đánh giá pipeline tổng thể.....	51
5.3.1 Các kịch bản thử nghiệm	52
5.3.2 Kết quả thực nghiệm	53
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	54
6.1 Kết luận	54
6.2 Hướng phát triển.....	55
TÀI LIỆU THAM KHẢO.....	58

DANH MỤC HÌNH VẼ

Hình 1.1	Một số thách thức thường gặp đối với ảnh cắt biển số trong thực tế (từ trái qua phải, từ trên xuống dưới: mờ nhòe do chuyển động, lóa sáng do đèn pha và thiếu sáng/nhiều hạt)	2
Hình 2.1	Kiến trúc tổng quát của mô hình YOLOv5	8
Hình 2.2	So sánh trực quan giữa khả năng định vị của hộp bao ngang (HBB) và hộp bao có hướng (OBB) trên biển số xe	9
Hình 3.1	Flow chart tổng quan pipeline xử lý nhận dạng biển số trên video	18
Hình 3.2	Kiến trúc tổng quát của mô hình OCR biển số	26
Hình 4.1	Sơ đồ use case tổng quan	35
Hình 4.2	Biểu đồ phụ thuộc gói	37
Hình 5.1	Ma trận nhầm lẫn chuẩn hóa của mô hình Quality Router sau fine-tune	49

DANH MỤC BẢNG BIỂU

Bảng 3.1	Thống kê dữ liệu phát hiện biển số	18
Bảng 3.2	Thống kê tập dữ liệu OCR	19
Bảng 3.3	Thống kê bố cục	19
Bảng 3.4	Thống kê màu nền biển số	20
Bảng 3.5	Thống kê dữ liệu đánh giá chất lượng biển số	20
Bảng 3.6	Phân bố nhãn trong dữ liệu chất lượng	21
Bảng 3.7	Cấu hình huấn luyện mô hình phát hiện biển số dạng OBB . .	22
Bảng 3.8	Kiến trúc STN alignment network	26
Bảng 3.9	Khối cơ bản SmallBasicBlockCBAM	27
Bảng 3.10	Backbone CNN của SmallLPR-Line-CTC	28
Bảng 3.11	Các head nhận dạng và bố cục	29
Bảng 4.1	Danh sách thư viện và công cụ sử dụng	38
Bảng 4.2	Các thành phần giao diện chính	41
Bảng 4.3	Các nhóm API chính của backend	42
Bảng 4.4	Các collection và document trong MongoDB	44
Bảng 4.5	Các chỉ mục MongoDB chính	45
Bảng 4.6	Cấu hình triển khai ứng dụng	45
Bảng 5.1	Môi trường đánh giá	47
Bảng 5.2	Kết quả mô hình phát hiện phương tiện kế thừa từ Che et al. [2]	48
Bảng 5.3	Kết quả validation của mô hình phát hiện biển số YOLOv8- OBB	48
Bảng 5.4	Kết quả validation của mô hình Quality Router	49
Bảng 5.5	Kết quả validation của checkpoint SmallLPR_Line_CTC_9501	50
Bảng 5.6	Kết quả ablation của mô hình OCR	51
Bảng 5.7	So sánh OCR trên tập dữ liệu chỉ gồm chữ và số	51
Bảng 5.8	Kết quả đánh giá pipeline tổng thể theo ba kịch bản thử nghiệm	52

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
ALPR	Nhận dạng biển số tự động (Automatic License Plate Recognition)
API	Giao diện lập trình ứng dụng (Application Programming Interface)
CMC	Bù trừ chuyển động camera (Camera Motion Compensation)
CNN	Mạng nơ-ron tích chập (Convolutional Neural Network)
CTC	Phân loại thời gian dạng kết nối (Connectionist Temporal Classification)
FPS	Số khung hình trên giây (Frames Per Second)
HMM	Mô hình Markov ẩn (Hidden Markov Model)
HOG	Biểu đồ véc-tơ gradient định hướng (Histogram of Oriented Gradients)
HTTP	Giao thức truyền tải siêu văn bản (Hypertext Transfer Protocol)
IoU	Chỉ số giao trên hợp (Intersection over Union)
ITS	Hệ thống giao thông thông minh (Intelligent Transportation Systems)
JWT	Tiêu chuẩn mã hóa thẻ xác thực (JSON Web Token)
LSTM	Mạng bộ nhớ dài-ngắn hạn (Long Short-Term Memory)
MOT	Bám vết đa đối tượng (Multi-Object Tracking)
OBB	Hộp giới hạn có hướng (Oriented Bounding Box)
OCR	Nhận dạng ký tự quang học (Optical Character Recognition)

Thuật ngữ	Ý nghĩa
ONNX	Định dạng trao đổi mô hình nơ-ron mở (Open Neural Network Exchange)
ReID	Nhận diện lại / Tái định danh (Re-Identification)
RNN	Mạng nơ-ron hồi quy (Recurrent Neural Network)
RTSP	Giao thức truyền phát video thời gian thực (Real-Time Streaming Protocol)
SSE	Server-Sent Events
STN	Mạng biến đổi không gian (Spatial Transformer Network)
SVM	Máy học véc-tơ hỗ trợ (Support Vector Machine)
YOLO	Mạng nơ-ron phát hiện đối tượng (You Only Look Once)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Ngày nay, cùng với sự phát triển mạnh mẽ của khoa học máy tính và trí tuệ nhân tạo, Hệ thống giao thông thông minh (Intelligent Transportation Systems - ITS) đang đóng vai trò quan trọng trong việc quản lý và điều hành giao thông đô thị. Trong đó, Nhận dạng biển số tự động (Automatic License Plate Recognition - ALPR) là một trong những thành phần quan trọng nhất, được ứng dụng rộng rãi trong giám sát an ninh, xử lý vi phạm giao thông, thu phí tự động và quản lý bãi đỗ xe.

Phần lớn các hệ thống ALPR thương mại hiện nay được thiết kế để hoạt động trong môi trường có kiểm soát (constrained environments), nơi camera được lắp đặt ở vị trí cố định với góc quay chuẩn, ánh sáng đồng đều và phương tiện di chuyển ở tốc độ chậm hoặc dừng hẳn. Tuy nhiên, khi triển khai vào môi trường thực tế không ràng buộc (unconstrained environments), chẳng hạn camera giám sát trên đường cao tốc hay camera hành trình, hiệu năng của các hệ thống này suy giảm nghiêm trọng. Nguyên nhân chính là dữ liệu thu được thường chứa đựng nhiều yếu tố gây nhiễu: biến đổi ánh sáng, thời tiết xấu, khoảng cách xa khiến độ phân giải biển số thấp, rung lắc camera và đặc biệt là hiện tượng mờ nhòe do chuyển động (motion blur) khi phương tiện di chuyển với tốc độ cao.



Hình 1.1: Một số thách thức thường gặp đối với ảnh cắt biển số trong thực tế (từ trái qua phải, từ trên xuống dưới: mờ nhòe do chuyển động, lóa sáng do đèn pha và thiếu sáng/nhiều hạt)

Từ những thách thức đó, việc xây dựng một hệ thống có khả năng nhận dạng chính xác biển số xe ngay cả khi phương tiện đang chuyển động trong điều kiện ngoại cảnh phức tạp là một yêu cầu cấp thiết. Xuất phát từ nhu cầu thực tiễn này, bài toán “Phát hiện và nhận dạng biển số xe chuyển động trong các nguồn video” được lựa chọn làm đề tài nghiên cứu và phát triển trong đề án.

1.2 Các giải pháp hiện tại và hạn chế

Các giải pháp ALPR thế hệ đầu chủ yếu dựa vào kỹ thuật xử lý ảnh truyền thống như phát hiện biên, phân tích đường viền, hoặc sử dụng các đặc trưng thủ công như HOG và Haar. Nhóm phương pháp này phụ thuộc lớn vào các ngưỡng cấu hình cứng, thiếu tính khái quát hóa và nhạy cảm với sự thay đổi của ngoại cảnh.

Sự bùng nổ của học sâu (Deep Learning), tiêu biểu là các mạng nơ-ron tích chập (CNN), mô hình phát hiện đối tượng họ YOLO và các mạng nhận dạng ký tự quang học (OCR), đã khắc phục phần lớn các nhược điểm trên. Tuy nhiên, các giải pháp hiện hành thường tiếp cận bài toán dưới góc độ xử lý ảnh tĩnh đơn khung hình (single-image ALPR). Khi áp dụng trực tiếp vào luồng video, việc ép buộc mô hình đưa ra dự đoán trên một khung hình đơn lẻ bị suy giảm chất lượng mà bỏ qua ngữ cảnh thời gian xung quanh thường dẫn đến kết quả nhận dạng sai lệch.

Một số giải pháp gần đây đã bắt đầu tích hợp thuật toán theo dõi đa đối tượng để bám vết phương tiện, nhưng vẫn tồn tại hai hạn chế chính. Thứ nhất, thuật toán bám vết truyền thống dễ mất dấu hoặc nhảy định danh (ID switch) khi phương tiện thay đổi vận tốc đột ngột hoặc bị che khuất. Thứ hai, phần lớn các giải pháp chưa thiết lập được cơ chế đánh giá chất lượng khung hình để chất lọc thông tin dư thừa theo thời gian (temporal redundancy); việc nhận dạng lặp lại trên mọi khung hình mà thiếu bộ lọc chất lượng không chỉ lãng phí tài nguyên mà còn khiến kết quả đầu ra thiếu ổn định.

1.3 Mục tiêu và định hướng giải pháp

Nhằm khắc phục các hạn chế nêu trên, đề án đề ra ba mục tiêu cụ thể:

1. **Xây dựng và chuẩn hóa các bộ dữ liệu đa nhiệm cho biển số Việt Nam.** Hệ thống dữ liệu được phân rã thành các tập chuyên biệt phục vụ từng bài toán lỗi, bao gồm: 40.465 ảnh gán nhãn Hộp giới hạn có hướng (Oriented Bounding Box - OBB) cho phát hiện biển số và hơn 33.000 ảnh cắt biển số cho huấn luyện OCR. Các tập dữ liệu được thiết kế để bao phủ đa dạng điều kiện ngoại cảnh phức tạp trong thực tế.
2. **Đề xuất luồng xử lý nhận dạng đa khung hình dựa trên học sâu.** Hệ thống phát hiện và bám vết quỹ đạo phương tiện, sau đó định vị và cắt vùng biển số bên trong từng track. Một bộ định tuyến chất lượng (Quality Router) tự động phân loại khung hình đủ rõ để OCR ngay và khung hình cần tích lũy thêm bằng chứng. Kết quả cuối cùng được tổng hợp từ nhiều khung hình thông qua thuật toán đối sánh chuỗi thời gian ký tự (Character Time-series Matching).
3. **Triển khai thành hệ thống phần mềm end-to-end trên nền tảng Web.** Ứng dụng cho phép tải lên video, kết nối camera giám sát qua luồng RTSP, quan sát tiến trình nhận dạng và tra cứu lịch sử kết quả kèm hình ảnh chứng cứ.

1.4 Đóng góp của đề án

Các đóng góp chính của đề án gồm: (i) xây dựng và chuẩn hóa các tập dữ liệu phục vụ nhiều tác vụ trong hệ thống ALPR, bao gồm dữ liệu phát hiện biển số dạng OBB, dữ liệu OCR biển số Việt Nam và dữ liệu đánh giá chất lượng khung hình; (ii) thiết kế pipeline nhận dạng biển số trên video theo hướng đa khung hình, kết hợp phát hiện phương tiện, phát hiện biển số, tracking, lọc chất lượng, OCR và bỏ phiếu kết quả theo track; (iii) huấn luyện và tích hợp các mô hình thành phần phù hợp với bối cảnh biển số Việt Nam, trong đó có mô hình phát hiện biển số YOLOv8-OBB, mô hình phân loại chất lượng khung hình và mô hình OCR SmallLPR-Line-CTC; (iv) xây dựng hệ thống Web end-to-end cho phép tải video, kết nối nguồn RTSP, theo dõi tiến trình xử lý, xem kết quả nhận dạng theo phương tiện và lưu lại lịch sử

nhận dạng kèm ảnh chứng cứ; và (v) đánh giá thực nghiệm các mô hình thành phần và pipeline tổng thể, từ đó chỉ ra hiệu quả của việc khai thác thông tin dư thừa theo thời gian trong bài toán nhận dạng biển số xe trên video.

Kết quả đạt được của đề án là một hệ thống thử nghiệm hoàn chỉnh, có khả năng tiếp nhận và xử lý video giao thông thực tế, hiển thị kết quả nhận dạng sau quá trình xử lý và lưu trữ dữ liệu phục vụ tra cứu lại. Phần đóng góp trọng tâm không nằm ở một mô hình đơn lẻ, mà ở việc tổ chức các mô hình phát hiện, theo dõi, OCR và hậu xử lý thành một luồng xử lý thống nhất cho bài toán nhận dạng biển số xe Việt Nam trên video.

1.5 Bố cục đề án

Báo cáo đề án được tổ chức thành sáu chương như sau.

Chương 1 giới thiệu đề tài, trình bày bối cảnh, các hạn chế của hệ thống ALPR hiện tại, mục tiêu nghiên cứu và các đóng góp chính.

Chương 2 trình bày nền tảng lý thuyết phục vụ cho hệ thống. Nội dung chương bao gồm bài toán nhận dạng biển số xe trên video, các mô hình phát hiện đối tượng, kiến trúc YOLOv5 và YOLOv8-OBb, thuật toán theo dõi đa đối tượng BoT-SORT, các hướng tiếp cận OCR.

Chương 3 mô tả phương pháp đề xuất. Chương này trình bày tổng quan pipeline xử lý, quá trình thu thập và xử lý dữ liệu, cách huấn luyện các mô hình thành phần gồm phát hiện phương tiện, phát hiện biển số, truy vết phương tiện, phân loại chất lượng khung hình và giới thiệu mô hình OCR SmallLPR-Line-CTC. Phần cuối chương mô tả các bước hậu xử lý, xác thực định dạng biển số và bỏ phiếu kết quả theo nhiều khung hình.

Chương 4 trình bày quá trình xây dựng và triển khai hệ thống. Nội dung chương bao gồm yêu cầu hệ thống, sơ đồ use case, kiến trúc tổng quan, các công nghệ sử dụng, thiết kế frontend, backend và API, cơ sở dữ liệu, kiểm thử chức năng và cấu hình triển khai.

Chương 5 đánh giá thực nghiệm các mô hình và pipeline tổng thể. Chương này mô tả môi trường thử nghiệm, tiêu chí đánh giá, kết quả của các mô hình thành phần như mô hình phát hiện phương tiện, mô hình phát hiện biển số và mô hình OCR, sau đó phân tích hiệu quả của pipeline trên các kịch bản video và các trường hợp lỗi thường gặp.

Chương 6 tổng kết các kết quả đã đạt được, nêu lại những đóng góp chính của đề án và trình bày các hướng phát triển tiếp theo nhằm cải thiện độ chính xác, tốc độ xử lý và khả năng triển khai của hệ thống trong môi trường thực tế.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

2.1 Ngữ cảnh bài toán

Trong lĩnh vực giao thông thông minh (ITS), bài toán nhận dạng biển số xe tự động (ALPR) đã được nghiên cứu rộng rãi và đạt được nhiều bước tiến lớn. Các giải pháp hiện hành chủ yếu tận dụng sức mạnh của các mô hình học sâu (Deep Learning) như mạng nơ-ron tích chập (CNN), tiêu biểu là họ mô hình YOLO, Faster R-CNN cho tác vụ phát hiện đối tượng, kết hợp cùng các công cụ nhận dạng ký tự quang học (OCR) như Pytesseract, PaddleOCR, CRNN hay LPRNet. Khi được tích hợp vào các nền tảng ứng dụng Web và giao tiếp qua API, các hệ thống này vận hành trơn tru và cung cấp độ chính xác rất cao trong các điều kiện môi trường lý tưởng.

Tuy nhiên, nguyên nhân chính khiến nhiều dự án và giải pháp ALPR hiện tại thất bại khi triển khai thực tiễn nằm ở sự phụ thuộc quá lớn vào các điều kiện có tính ràng buộc cao (constrained environments). Các hệ thống này thường yêu cầu camera đặt cố định ở góc chụp trực diện, phương tiện dừng đỗ hoặc di chuyển cực chậm, và ánh sáng môi trường phải đồng đều. Sự thất bại khi hoạt động trong môi trường không kiểm soát (unconstrained environments) xuất phát từ hai nguyên nhân chính. Thứ nhất, các tập dữ liệu được sử dụng để huấn luyện mô hình (như YOLO hay R-CNN) thường thiếu vắng các mẫu ảnh ở điều kiện ánh sáng yếu, lóa sáng hay góc chụp nghiêng lệch. Thứ hai, các công nghệ OCR hiện hành (điển hình như Pytesseract) vốn được thiết kế cho văn bản phẳng; chúng đòi hỏi độ tương phản đen trắng rõ rệt và ký tự không bị méo mó. Do đó, khi áp dụng lên luồng video thực tế — nơi biển số liên tục bị biến dạng phối cảnh, mờ nhòe do chuyển động và chịu nhiều ánh sáng — khả năng trích xuất đặc trưng của mô hình giảm sút nghiêm trọng, dẫn đến việc dự đoán sai lệch hoặc bỏ sót hoàn toàn ký tự.

Từ những phân tích trên, ngữ cảnh của đề án này được đặt ra nhằm giải quyết bài toán nhận dạng biển số đối với các phương tiện di chuyển ở tốc độ vừa phải (không quá nhanh), nhưng xuất hiện dưới các góc chụp rất đa dạng. Ngữ cảnh này mô phỏng chân thực bối cảnh thu thập dữ liệu từ camera an ninh đặt ở các góc ngã tư hoặc camera hành trình, nơi biển số xe liên tục thay đổi kích thước, vị trí và độ nghiêng theo thời gian thực. Tiêu chuẩn khắt khe nhất được đặt ra cho hệ thống là khả năng đạt đến ngưỡng nhận thức của con người: "miễn là mắt người có thể quan sát và dịch được chuỗi ký tự trên đoạn video, hệ thống cũng phải trích xuất được kết quả chính xác".

Để đạt được tiêu chuẩn "mắt người" trong một kịch bản góc chụp đa dạng như

vậy, hệ thống không thể hoạt động theo cơ chế ép buộc dự đoán trên các khung hình tĩnh (single-frame) rời rạc vốn chứa đầy rủi ro nhiễu loạn. Trong thực tế, con người không bao giờ nhìn vào một khoảnh khắc tĩnh bị nhòe để đoán biển số, mà quan sát sự dịch chuyển của phương tiện qua một chuỗi thời gian để chấp vá thông tin. Do đó, bài toán đòi hỏi một luồng xử lý linh hoạt ở cấp độ video, tích hợp khả năng theo dõi quỹ đạo phương tiện và đánh giá chất lượng ảnh. Cơ chế tổng hợp thông tin dư thừa theo thời gian (temporal redundancy) cho phép hệ thống chọn lọc các khung hình có chất lượng tốt nhất trong cùng một quỹ đạo phương tiện. Nhờ đó, độ chính xác nhận dạng được cải thiện đáng kể so với các mô hình OCR xử lý từng khung hình rời rạc.

2.2 Các nghiên cứu tương tự

Trong những năm gần đây, bài toán nhận dạng biển số xe tự động (ALPR) đã thu hút sự chú ý mạnh mẽ từ cộng đồng nghiên cứu, đặc biệt là khi có sự ra đời của các kiến trúc học sâu. Đối với hướng tiếp cận trên các khung hình tĩnh, Pan và cộng sự đã đề xuất một hệ thống nhận dạng sử dụng mô hình YOLOv7 kết hợp với LPRNet, đạt được sự ổn định nhất định trên các tập dữ liệu biển số Trung Quốc. Tuy nhiên, giải pháp này nhanh chóng bộc lộ điểm yếu và suy giảm độ chính xác khi đối mặt với hiện tượng che khuất hoặc biến đổi ánh sáng phức tạp. Tương tự, Moussaoui và các cộng sự đã ứng dụng mô hình YOLOv8 kết hợp với các kỹ thuật tiền xử lý tăng cường hình ảnh để cải thiện độ rõ nét của biển số trước khi đưa vào module OCR. Dù vậy, phương pháp này vẫn chưa xử lý phần lớn được sự suy giảm tỷ lệ nhận dạng khi gặp các ký tự bị mờ nhòe do chuyển động (motion blur) hoặc các ký tự dính liền nhau. Ở một phạm vi hẹp hơn, Habeeb và cộng sự hay Youssef và cộng sự đã sử dụng các phiên bản YOLO cũ hơn (như YOLOv2, YOLOv3) để nhận diện biển số đặc thù của từng quốc gia (Iraq, Ai Cập). Các nghiên cứu này cho thấy tốc độ xử lý rất nhanh nhưng lại phụ thuộc quá nhiều vào kích thước đối tượng và thường chỉ hoạt động tốt trong các kịch bản bị ràng buộc chặt chẽ về khoảng cách cũng như góc chụp.

Để giải quyết vấn đề biến dạng hình học trong các môi trường không kiểm soát (unconstrained environments), Silva và Jung đã đề xuất một luồng xử lý học sâu cho phép phát hiện và nắn chỉnh (rectification) các biển số bị méo góc trước khi đưa vào hệ thống nhận dạng. Mặc dù mang lại hiệu quả tích cực trong việc cải thiện kết quả OCR, bộ dữ liệu thử nghiệm của họ vẫn thiếu vắng các kịch bản thời tiết hoặc ánh sáng thực sự khắc nghiệt. Theo một hướng tiếp cận khác nhằm khắc phục giới hạn của mạng nơ-ron tích chập (CNN) truyền thống, Azadbakht và cộng sự đã áp dụng kiến trúc Vision Transformer (Vision-LPR) để nhận dạng các biển số bị mờ và có độ phân giải thấp. Mặc dù đạt được độ chính xác ấn tượng nhờ cơ chế

chú ý toàn cục (global attention), phương pháp này lại đòi hỏi chi phí tính toán lớn và có tốc độ suy luận chậm, gây rào cản lớn cho việc triển khai trên các hệ thống giám sát yêu cầu thời gian thực.

Đáng chú ý nhất, đối với kịch bản nhận dạng phương tiện di chuyển trên luồng dữ liệu video, một số nghiên cứu đã bắt đầu nhận ra rủi ro của việc dựa vào khung hình đơn lẻ và chuyển hướng sang khai thác đặc trưng chuỗi thời gian. Nhóm tác giả Laroca, Severo và cộng sự [1] đã giới thiệu hệ thống ALPR thời gian thực sử dụng mạng Fast-YOLO, đồng thời ra mắt bộ dữ liệu UFPR-ALPR mô phỏng kịch bản cả camera và phương tiện cùng di chuyển. Cải tiến đáng chú ý trong nghiên cứu của họ, cũng như trong công trình của Gonçalves và cộng sự, là việc bước đầu áp dụng thông tin dư thừa theo thời gian (temporal redundancy). Bằng cách nhận dạng độc lập từng khung hình của cùng một phương tiện và áp dụng cơ chế bầu chọn theo số đông (majority voting), tỷ lệ nhận dạng của họ đã tăng vọt từ 85.45% lên 93.53% trên tập dữ liệu SSIG. Mặc dù cơ chế này đã chứng minh được sức mạnh của việc kết hợp đa khung hình, các phương pháp bầu chọn nêu trên vẫn mang tính chất thống kê cơ bản. Chúng thiếu vắng một thuật toán bám vết đa đối tượng (multi-object tracking) độ chính xác cao và chưa có bộ định tuyến để đánh giá chất lượng (quality routing) nhằm chủ động loại bỏ các khung hình nhiễu trước khi tiến hành đối sánh. Đây chính là khoảng trống công nghệ lớn nhất mà đề án này tập trung khai thác và hoàn thiện.

2.3 Các mô hình phát hiện đối tượng


2.3.1 YOLOv5

YOLOv5 là một họ mô hình phát hiện đối tượng một giai đoạn, trực tiếp dự đoán đồng thời hộp bao và nhãn lớp từ bản đồ đặc trưng mà không cần giai đoạn sinh vùng đề xuất như các mô hình hai giai đoạn (Faster R-CNN, Mask R-CNN). Nhờ đó, độ trễ suy luận được giảm thiểu đáng kể, phù hợp với các hệ thống xử lý video thời gian thực.

Trong đề án này, YOLOv5 được kế thừa từ Che et al. [2] và sử dụng nguyên vẹn không qua fine-tune, đảm nhiệm duy nhất tầng phát hiện phương tiện. Đầu ra là các hộp bao quanh xe máy, ô tô, xe tải trong khung hình, phục vụ làm vùng quan tâm (RoI) cho tầng phát hiện biển số phía sau.

Mô hình phù hợp với vai trò này vì ba lý do chính. Thứ nhất, kiến trúc một giai đoạn mang lại tốc độ cao, đáp ứng yêu cầu xử lý liên tục trên luồng video. Thứ hai, cơ chế neck PANet tổng hợp đặc trưng đa tỉ lệ, cho phép phát hiện phương tiện ở nhiều kích thước khác nhau — từ xe máy nhỏ ở xa đến xe tải lớn ở gần camera — trong cùng một khung hình. Thứ ba, định vị phương tiện trước giúp pipeline hoạt

động phân cấp: khoanh vùng tìm kiếm, loại bỏ nhiễu nền và cung cấp vùng ảnh sạch hơn cho tầng phát hiện biến số.



Hình 2.1: Kiến trúc tổng quát của mô hình YOLOv5

2.3.2 YOLOv8 OBB

Bên cạnh kiến trúc phát hiện đối tượng tiêu chuẩn, YOLOv8 cung cấp thêm biến thể YOLOv8 OBB [3] được thiết kế đặc thù để nhận diện các vật thể có độ nghiêng và góc xoay phức tạp. Điểm khác biệt chính trong kiến trúc của YOLOv8 OBB so với các mô hình truyền thống nằm ở phần đầu dự đoán phân tách không neo (anchor-free split Ultralytics head). Thay vì bị giới hạn bởi việc dự đoán các hộp giới hạn song song với trục tọa độ của bức ảnh, mạng nơ-ron được bổ sung thêm một tham số góc xoay ở lớp đầu ra, chuyển đổi không gian tính toán sang định dạng xywhr. Trong cấu trúc biểu diễn này, thành phần x và y đại diện cho tọa độ tâm, w và h là chiều rộng và chiều cao, còn thành phần r đóng vai trò lưu trữ góc xoay của đối tượng so với trục tham chiếu. Thông qua cơ chế lan truyền thẳng, mạng sẽ xuất ra véc-tơ năm chiều này, sau đó hệ thống suy luận mới thực hiện quá trình ánh xạ toán học để chuyển đổi từ định dạng xywhr về tọa độ không gian chuẩn hóa của bốn điểm góc.

Sự thay đổi về biểu diễn tham số hình học đòi hỏi hệ thống hàm mất mát (loss function) của YOLOv8 OBB cũng phải được thiết kế lại. Quá trình tính toán lỗi định vị không chỉ dựa trên mức độ chồng lấp của hai hình chữ nhật thông thường, mà mọi sai số đều được xử lý trực tiếp trên không gian xywhr. Việc kết hợp tham

số góc xoay vào hàm mất mát IoU (Intersection over Union) giúp mạng nơ-ron bị phạt nặng hơn khi dự đoán sai hướng của đối tượng, buộc mô hình phải học cách tinh chỉnh góc xoay sao cho đường viền của hộp giới hạn ôm sát nhất vào các cạnh thực tế của vật thể. Đặc điểm kiến trúc không neo (anchor-free) kết hợp cùng hàm mất mát tối ưu góc xoay này giúp mô hình triệt tiêu hoàn toàn sự phụ thuộc vào các hộp neo cố định, mang lại độ linh hoạt cao khi đối tượng bị xoay ở các biên độ bất kỳ.

Đối với bài toán nhận dạng biển số xe trên luồng video không kiểm soát, phương tiện giao thông thường xuyên di chuyển với quỹ đạo đa dạng, khiến hình ảnh biển số thu được hiếm khi nằm ngang chuẩn. Việc ứng dụng cấu trúc đầu ra xywhr của YOLOv8 OBB cho phép hệ thống xác định chuẩn xác tọa độ bốn điểm góc của biển số bất chấp các góc nghiêng lệch. Dữ liệu tọa độ không gian này là cơ sở hình học then chốt để áp dụng phép toán biến đổi phối cảnh (perspective transform). Quá trình này sẽ kéo phẳng vùng biển số bị méo về dạng hình chữ nhật chuẩn, cắt bỏ tối đa các điểm ảnh thuộc về cảnh nền vốn thường xuất hiện ở bốn góc nếu dùng hộp giới hạn thẳng đứng. Nhờ đặc tính kiến trúc vượt trội này, hệ thống cung cấp các vùng ảnh đầu vào được chuẩn hóa hình học, giúp nâng cao độ ổn định và chính xác cho mô hình nhận dạng chuỗi ký tự (OCR) ở giai đoạn tiếp theo.



Hình 2.2: So sánh trực quan giữa khả năng định vị của hộp bao ngang (HBB) và hộp bao có hướng (OBB) trên biển số xe

2.4 Các thuật toán truy vết đối tượng

2.4.1 BoT-SORT

BoT-SORT (Robust Associations Multi-Pedestrian Tracking) là thuật toán bám vết đa đối tượng trực tuyến được Aharon, Orfaig và Bobrovsky đề xuất trong bối cảnh các tracker họ SORT vẫn còn hạn chế về mô hình chuyển động, bù chuyển động camera và cách kết hợp đặc trưng ngoại hình [4]. Thuật toán đi theo mô hình *tracking-by-detection*: tại mỗi khung hình, bộ phát hiện đối tượng sinh ra các hộp bao mới; bộ theo dõi dự đoán trạng thái của các track đã tồn tại; sau đó bài toán gán giữa track và detection được giải như một bài toán tối ưu ghép cặp. BoT-SORT không thay thế detector, mà tập trung cải thiện ba thành phần của tracker: bộ lọc Kalman, bù chuyển động camera và hàm chi phí kết hợp IoU-ReID.

Với mô hình chuyển động, BoT-SORT vẫn dùng bộ lọc Kalman rời rạc dưới giả thiết vận tốc không đổi, nhưng thay đổi cách biểu diễn trạng thái hộp bao. Trong SORT, trạng thái dùng diện tích hộp và tỷ lệ khung hình; trong DeepSORT, trạng thái dùng tỷ lệ khung hình a và chiều cao h . Theo các tác giả, cách biểu diễn này có thể làm ước lượng chiều rộng thiếu chính xác. Vì vậy BoT-SORT định nghĩa trực tiếp trạng thái theo tâm, chiều rộng, chiều cao và đạo hàm theo thời gian:

$$\mathbf{x}_k = [x_c(k), y_c(k), w(k), h(k), \dot{x}_c(k), \dot{y}_c(k), \dot{w}(k), \dot{h}(k)]^\top.$$

Vector đo từ detector chỉ gồm bốn đại lượng quan sát được:

$$\mathbf{z}_k = [z_{x_c}(k), z_{y_c}(k), z_w(k), z_h(k)]^\top.$$

Với ma trận chuyển trạng thái $\mathbf{F}$, ma trận quan sát $\mathbf{H}$, hiệp phương sai trạng thái $\mathbf{P}$, nhiễu quá trình $\mathbf{Q}_k$ và nhiễu đo $\mathbf{R}_k$, bước dự đoán có dạng:

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}\hat{\mathbf{x}}_{k-1|k-1}, \quad \mathbf{P}_{k|k-1} = \mathbf{F}\mathbf{P}_{k-1|k-1}\mathbf{F}^\top + \mathbf{Q}_k.$$

Khi có detection được gán vào track, Kalman gain và trạng thái hậu nghiệm được cập nhật bởi:

$$\mathbf{K}_k = \mathbf{P}_{k|k-1}\mathbf{H}^\top(\mathbf{H}\mathbf{P}_{k|k-1}\mathbf{H}^\top + \mathbf{R}_k)^{-1},$$

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k(\mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_{k|k-1}).$$

Trong paper, $\mathbf{Q}_k$ và $\mathbf{R}_k$ được đặt phụ thuộc vào kích thước hộp bao, ví dụ các nhiễu vị trí và kích thước tỷ lệ với $\hat{w}$ và $\hat{h}$. Cách đặt này phản ánh trực giác rằng hộp lớn thường có sai số tuyệt đối lớn hơn hộp nhỏ.

Thành phần thứ hai của BoT-SORT là Camera Motion Compensation (CMC). Trong các tracker dựa trên IoU, nếu camera dịch chuyển, hộp dự đoán của track có thể lệch khỏi detection thật dù đối tượng không đổi danh tính. BoT-SORT ước lượng chuyển động nền giữa hai khung hình bằng đăng ký ảnh và biểu diễn nó bằng ma trận affine:

$$\mathbf{A}_{k-1}^k = [\mathbf{M} \mid \mathbf{T}] = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix}.$$

Từ $\mathbf{M}$ và $\mathbf{T}$, thuật toán xây dựng ma trận mở rộng $\tilde{\mathbf{M}}$ và vector $\tilde{\mathbf{T}}$ để hiệu chỉnh dự đoán của Kalman:

$$\hat{\mathbf{x}}'_{k|k-1} = \tilde{\mathbf{M}}\hat{\mathbf{x}}_{k|k-1} + \tilde{\mathbf{T}}, \quad \mathbf{P}'_{k|k-1} = \tilde{\mathbf{M}}\mathbf{P}_{k|k-1}\tilde{\mathbf{M}}^\top.$$

Sau bước này, trạng thái đã được đưa về hệ tọa độ của khung hình hiện tại trước khi ghép nối với detection.

Thành phần thứ ba là chiến lược kết hợp IoU và ReID. Với track i và detection j , khoảng cách hình học được tính bằng:

$$d_{ij}^{iou} = 1 - \text{IoU}(\hat{b}_i, b_j),$$

trong đó $\hat{b}_i$ là hộp dự đoán của track và b_j là hộp detection. Khoảng cách ngoại hình là cosine distance giữa đặc trưng trung bình của track e_i và đặc trưng detection f_j :

$$d_{ij}^{cos} = 1 - e_i^\top f_j.$$

Đặc trưng track được cập nhật bằng trung bình trượt mũ:

$$e_i^k = \alpha e_i^{k-1} + (1 - \alpha) f_i^k.$$

Thay vì dùng tổng có trọng số $C = \lambda A_a + (1 - \lambda) A_m$, BoT-SORT dùng cơ chế lọc theo ngưỡng rồi lấy chi phí nhỏ hơn:

$$\hat{d}_{ij}^{cos} = \begin{cases} 0.5 d_{ij}^{cos}, & d_{ij}^{cos} < \theta_{emb} \wedge d_{ij}^{iou} < \theta_{iou}, \\ 1, & \text{ngược lại,} \end{cases} \quad C_{ij} = \min\{d_{ij}^{iou}, \hat{d}_{ij}^{cos}\}.$$

Ma trận chi phí C được đưa vào thuật toán Hungarian để tìm phép gán tối ưu. Như vậy, BoT-SORT giữ được ưu điểm của IoU trong định vị ngắn hạn, đồng thời tận dụng ReID để duy trì định danh khi các đối tượng gần nhau, bị che khuất hoặc có chuyển động phức tạp.

2.5 Các mô hình nhận diện ký tự quang học (OCR)

2.5.1 Các phương pháp nhận dạng phân đoạn ký tự

Các phương pháp nhận dạng biến số dựa trên phân đoạn ký tự (segmentation-based) hoạt động theo nguyên lý tách rời bước định vị ký tự ra khỏi bước nhận dạng. Sau khi ảnh biến số được trích xuất, hệ thống thực hiện phân đoạn để xác định vùng ảnh chứa từng ký tự riêng lẻ, sau đó đưa từng ký tự đã phân đoạn vào bộ phân loại hoặc bộ nhận dạng độc lập. Do đó, chất lượng của toàn bộ hệ thống phụ thuộc trực tiếp vào độ chính xác của giai đoạn phân đoạn. Mục này tập trung vào hai nhóm phương pháp phân đoạn ký tự có tính đại diện trong giai đoạn phát triển từ học máy truyền thống sang học sâu, bao gồm: phương pháp dựa trên trích xuất đặc trưng thủ công kết hợp phân loại thống kê, và phương pháp phát hiện đối tượng bằng mạng nơ-ron tích chập sâu.

Phương pháp học máy truyền thống Trước khi các kiến trúc mạng nơ-ron tích chập sâu được ứng dụng rộng rãi, nhóm phương pháp học máy truyền thống là hướng tiếp cận chủ đạo trong bài toán nhận dạng ký tự biến số. Trong các phương pháp này, mỗi ký tự sau khi được phân đoạn ra khỏi ảnh biến số sẽ được đưa qua một pipeline gồm ba bước tuần tự: trích xuất đặc trưng thủ công, giảm chiều dữ liệu, và phân loại.

Về trích xuất đặc trưng, Histogram of Oriented Gradients (HOG) là descriptor được sử dụng phổ biến nhất. Phương pháp này hoạt động bằng cách chia ảnh ký tự thành các ô (cell) cố định, tính histogram gradient theo nhiều hướng trong từng ô, sau đó chuẩn hóa theo khối (block) để tăng tính bất biến với thay đổi độ sáng cục bộ. Khan et al. đề xuất kiến trúc kết hợp kênh độ sáng L từ không gian màu CIE-Lab, nhị phân hóa thích nghi, sau đó hợp nhất đặc trưng HOG với các đặc trưng hình học (geometric features), và áp dụng phương pháp lựa chọn đặc trưng dựa trên entropy trước khi đưa vào bộ phân loại SVM. Để giảm chiều không gian đặc trưng và loại bỏ thành phần nhiễu, nhiều nghiên cứu áp dụng thêm Phân tích thành phần chính (PCA) trước bước phân loại. Về phía phân loại, Support Vector Machine (SVM) được huấn luyện theo phương thức one-vs-all để nhận dạng 36 lớp ký tự (10 chữ số và 26 chữ cái). Một hướng khác sử dụng Hidden Markov Model (HMM) để mô hình hóa chuỗi ký tự như một quá trình Markov ẩn, trong đó mỗi trạng thái ẩn tương ứng với một ký tự và các đặc trưng trực quan là quan sát; ưu điểm của HMM là có khả năng mô hình hóa phụ thuộc ngữ cảnh giữa các ký tự liên kề, song yêu cầu định nghĩa chặt chẽ về cấu trúc biến số đầu vào.

Nhược điểm căn bản của nhóm phương pháp này nằm ở việc phụ thuộc hoàn toàn vào thiết kế đặc trưng thủ công, vốn thiếu khả năng học các biểu diễn phức tạp

và thích nghi tự động với dữ liệu trong môi trường thực tế. Quan trọng hơn, toàn bộ hiệu năng của hệ thống phụ thuộc nghiêm ngặt vào chất lượng của bước phân đoạn ký tự đứng trước: nếu bước phân đoạn tạo ra ký tự bị cắt thiếu, dính liền hay lệch vị trí, bộ phân loại SVM hay HMM hoàn toàn không có cơ chế bù đắp sai sót này.

Phương pháp phát hiện ký tự bằng mô hình học sâu Gonçalves et al. đã chỉ ra trong công trình benchmark về phân đoạn ký tự biển số (2016) rằng hiệu quả của bước phân đoạn ký tự cần đạt mức gần tối ưu thì OCR mới có thể cho kết quả nhận dạng cao; mặc dù một số hệ thống đạt tốc độ xử lý ảnh tương lên tới 448 FPS, tỷ lệ nhận dạng chính xác toàn bộ biển số vẫn chưa đạt 65% trên tập kiểm tra, cho thấy đây là điểm nghẽn lớn của các phương pháp phân đoạn truyền thống. Để khắc phục hạn chế này, một nhánh nghiên cứu quan trọng đã chuyển hướng tiếp cận bài toán phân đoạn ký tự như một bài toán phát hiện đối tượng, trong đó các mô hình học sâu được huấn luyện để dự đoán bounding box và nhãn lớp của từng ký tự trực tiếp trên ảnh biển số.

Laroca et al. [1] là một trong những công trình tiên phong theo hướng này, đề xuất hệ thống ALPR hai giai đoạn hoàn toàn dựa trên kiến trúc YOLO. Cụ thể, các tác giả sử dụng Fast-YOLO để phát hiện phương tiện và định vị biển số, sau đó áp dụng một kiến trúc lấy cảm hứng từ Fast-YOLO thứ hai — được các tác giả đặt tên là CR-NET, bao gồm 11 lớp đầu của YOLO cùng bốn lớp tích chập bổ sung để tăng phi tuyến tính — chuyên biệt cho bài toán phân đoạn và nhận dạng ký tự đồng thời. Mô hình CR-NET xử lý ảnh biển số đã được cắt ra, dự đoán bounding box và nhãn lớp ký tự trong một lần truyền thuận, và thứ tự chuỗi được suy luận theo tọa độ hoành độ của tâm bounding box. Hệ thống đạt tỷ lệ nhận dạng 93.53% và tốc độ 47 FPS trên tập dữ liệu SSIG. Một điểm đáng chú ý là các tác giả sử dụng kỹ thuật bù dư thừa thời gian (temporal redundancy) bằng cách tổng hợp dự đoán từ nhiều khung hình liên tiếp tương ứng với cùng một phương tiện theo phương thức bỏ phiếu đa số, nhờ đó cải thiện tỷ lệ nhận dạng từ 85.45% lên 93.53%.

Kessentini et al. tiếp tục hướng tiếp cận này bằng cách điều chỉnh kiến trúc YOLOv2 để phù hợp với đặc thù biển số Tunisia. Henry et al. (2020) sử dụng phiên bản cải tiến của YOLOv3 tích hợp khối Spatial Pyramid Pooling (SPP), gọi là YOLOv3-SPP, cho phép phát hiện ký tự ở nhiều tỷ lệ khác nhau; đóng góp này đặc biệt phù hợp với định dạng biển số hai hàng phổ biến ở nhiều quốc gia, vốn là một thách thức mà các phiên bản YOLO trước chưa giải quyết tốt.

Selmi et al. (2020) trong công trình DELP-DAR đề xuất sử dụng Mask R-CNN cho bước phân đoạn ký tự. Thay vì giữ nguyên kiến trúc gốc, các tác giả lược bỏ nhánh phân đoạn mask của Mask R-CNN và chỉ giữ lại lớp RoIAlign — cơ chế

nội suy song tuyến thay thế cho RoI Pooling truyền thống nhằm duy trì sự căn chỉnh không gian chính xác ở mức dưới pixel — kết hợp với backbone tương tự GoogLeNet nhưng có ít tham số hơn. Sau bước phát hiện ký tự ứng viên, các tác giả áp dụng một tập luật heuristic để loại bỏ kết quả nhiễu và giải quyết nhầm lẫn giữa chữ cái và chữ số có hình dạng tương tự nhau. Hệ thống DELP-DAR được đánh giá trên bốn bộ dữ liệu đa ngôn ngữ và đa điều kiện môi trường, bao gồm Caltech, PKU, AOLP và Tunisian.

Mặc dù các phương pháp phát hiện ký tự dựa trên học sâu cho thấy ưu thế vượt trội so với các kỹ thuật truyền thống về độ chính xác trong điều kiện môi trường phức tạp, chúng vẫn tồn tại một hạn chế chung đáng chú ý: để huấn luyện hiệu quả, các mô hình này đòi hỏi lượng dữ liệu lớn với nhãn bounding box được gán thủ công ở cấp độ từng ký tự riêng lẻ — một công việc tốn kém và mất nhiều thời gian hơn so với gán nhãn ở cấp độ chuỗi biển số. Ngoài ra, thứ tự của các ký tự trong chuỗi kết quả phải được suy luận gián tiếp từ tọa độ bounding box chứ không được mô hình hóa trực tiếp, điều này dễ gây lỗi với các biển số có bố cục phi tuyến tính hoặc nhiễu hàng.

2.5.2 Các phương pháp nhận dạng không phân đoạn ký tự

Nhận dạng chuỗi ký tự không cần phân mảnh (segmentation-free) đã trở thành tiêu chuẩn mới trong các hệ thống nhận dạng văn bản trong tự nhiên cũng như bài toán ALPR hiện đại. Phương pháp này khắc phục hiệu quả nhược điểm của các kỹ thuật truyền thống vốn dễ thất bại khi các ký tự dính liền nhau, bị che khuất hoặc mờ nhòe do chuyển động. Dựa trên cơ chế giải mã và mô hình hóa chuỗi, các phương pháp này được chia thành hai nhóm kiến trúc chính, cùng với sự ra đời của các nền tảng đóng gói phục vụ triển khai thực tiễn.

Nhóm mô hình dựa trên hàm mất mát CTC (CTC-based Models)

Connectionist Temporal Classification (CTC) là một kỹ thuật quan trọng cho phép mạng nơ-ron ánh xạ trực tiếp từ chuỗi đặc trưng hình ảnh sang chuỗi ký tự đích mà không yêu cầu dữ liệu phải được phân mảnh sẵn ở cấp độ từng ký tự. Kiến trúc tiêu biểu cho nhóm này là CRNN [5], kết hợp mạng tích chập (CNN) để trích xuất đặc trưng hình ảnh và mạng hồi quy (RNN/LSTM) để mô hình hóa ngữ cảnh thời gian, sau đó dùng thuật toán CTC để giải mã và loại bỏ các ký tự lặp.

Tuy nhiên, trong các bài toán yêu cầu tốc độ thời gian thực như nhận dạng biển số, việc sử dụng các lớp LSTM thường tạo ra điểm nghẽn về mặt tính toán. Để giải quyết vấn đề này, các kiến trúc như LPRNet [6] đã được đề xuất nhằm loại bỏ hoàn toàn mạng RNN, chỉ sử dụng mạng CNN nhẹ kết hợp trực tiếp với hàm mất mát

CTC. Ưu điểm chính của họ mô hình dựa trên CTC là khả năng xuất ra toàn bộ chuỗi ký tự chỉ thông qua một lần lan truyền tiến (single forward pass) duy nhất, loại bỏ vòng lặp giải mã phức tạp. Gần đây, việc kết hợp CTC với các mô hình thị giác tiên tiến như SVTRv2 [7] cũng cho thấy tốc độ và độ chính xác vượt trội so với các kiến trúc mã hóa - giải mã (Encoder-Decoder) phức tạp. Đây là hướng tiếp cận đặc biệt phù hợp cho các luồng xử lý video đòi hỏi độ trễ cực thấp.

Nhóm mô hình dựa trên cơ chế Chú ý và Transformer (Attention/Transformer-based Models)

Để giải quyết bài toán nhận dạng văn bản bị méo mó, biến dạng phối cảnh hoặc che khuất nghiêm trọng, các kiến trúc dựa trên cơ chế tự chú ý (Self-Attention) và Transformer đã được ứng dụng rộng rãi nhờ khả năng nắm bắt ngữ cảnh toàn cục mạnh mẽ. Tiêu biểu, mô hình TrOCR [8] loại bỏ hoàn toàn mạng CNN truyền thống, thay vào đó tận dụng sức mạnh của các mạng Transformer thị giác (ViT, DeiT) và mạng ngôn ngữ (RoBERTa) đã được huấn luyện trước ở quy mô lớn để sinh văn bản trực tiếp theo từng mảnh từ vựng (wordpiece).

Tuy nhiên, các mô hình sinh tự hồi quy (Autoregressive - AR) thông thường thường bị giới hạn bởi tính đơn hướng (từ trái sang phải) và tốc độ giải mã chậm. Để khắc phục, kiến trúc PARSeq [9] đã áp dụng mô hình ngôn ngữ hoán vị (Permutation Language Modeling), cho phép mạng nơ-ron học được các xác suất có điều kiện dựa trên các tập con ngữ cảnh tùy ý. Thiết kế này hợp nhất khả năng giải mã không tự hồi quy (NAR) song song và tinh chỉnh lặp lại (iterative refinement), mang lại độ ổn định cao đối với các văn bản bị xoay nghiêng hoặc mờ nhòe trong tự nhiên. Dù đem lại năng lực mô hình hóa ngôn ngữ vượt trội, hạn chế lớn của các mô hình họ Transformer là dung lượng tham số lớn, chi phí tính toán cao và có chi phí suy luận cao hơn so với các mô hình CNN nhẹ. Việc áp dụng chúng vào bài toán biển số xe — vốn có cấu trúc ngữ pháp rất ngắn và đơn giản — đòi hỏi sự đánh đổi khắt khe về tài nguyên hệ thống.

Các framework OCR thực tiễn (Practical OCR Frameworks)

Song song với các nghiên cứu lý thuyết, việc triển khai công nghệ OCR vào các sản phẩm thực tế đã được thúc đẩy mạnh mẽ bởi các nền tảng mã nguồn mở tối ưu hóa cao. Nổi bật nhất là EasyOCR [10], một framework cung cấp giải pháp toàn trình sử dụng thuật toán CRAFT cho việc phát hiện và mạng CRNN (ResNet + LSTM + CTC) để nhận dạng. Nền tảng này hỗ trợ hơn 80 ngôn ngữ và cho phép dễ dàng tích hợp, thử nghiệm nhanh chóng trên các phần cứng phổ thông. Ở mức độ tối ưu công nghiệp sâu sắc hơn, hệ sinh thái PaddleOCR [11] cung cấp các pipeline (luồng xử

lý) như PP-OCRv4 với hai phiên bản Server và Mobile. Bằng việc chắt lọc các kỹ thuật học sâu tiên tiến nhất, các mô hình này đạt được sự cân bằng hiệu quả giữa dung lượng nhỏ gọn, tốc độ suy luận rất nhanh (chỉ khoảng vài mili-giây trên GPU) và độ chính xác cao. Ngược lại, các công cụ truyền thống như Pytesseract OCR, dù đã được nâng cấp lõi nhận dạng LSTM, vẫn bộc lộ nhiều rào cản khi ứng dụng vào hệ thống giao thông. Do bản chất được thiết kế cho văn bản phẳng (document OCR), chúng đòi hỏi điều kiện ánh sáng chuẩn, độ tương phản đen trắng rõ rệt và thường thường thất bại trước các biển số bị biến dạng phối cảnh, nhiễu hạt hoặc thiếu sáng trong các kịch bản môi trường không kiểm soát. Sự đối lập này một lần nữa khẳng định sự cần thiết của các luồng xử lý nhận dạng chuyên biệt tích hợp sâu công nghệ học sâu thay vì phụ thuộc vào các công cụ OCR đại trà.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Tổng quan giải pháp


Pipeline của hệ thống được thiết kế theo hướng xử lý video theo quỹ đạo phương tiện, thay vì nhận dạng biển số độc lập trên từng khung hình. Đầu vào của hệ thống có thể là video tải lên hoặc một đoạn video được trích từ phiên giám sát RTSP. Trong cả hai trường hợp, dữ liệu đều được chuẩn hóa thành chuỗi khung hình thông qua lớp `FrameSource`; nếu người dùng chọn chế độ tiền xử lý, các phép tăng cường như cải thiện tương phản hoặc giảm nhiễu được áp dụng trước khi đưa khung hình vào các mô hình học sâu.

Trên mỗi khung hình, hệ thống trước tiên phát hiện phương tiện bằng mô hình YOLO. Các hộp bao phương tiện sau đó được đưa vào bộ theo dõi đa đối tượng để gán và duy trì `track_id` ổn định theo thời gian. Việc đặt bước phát hiện phương tiện ở đầu pipeline giúp giảm vùng tìm kiếm cho biển số, đồng thời tạo cơ sở để gom nhiều quan sát của cùng một xe vào một track thống nhất.

Với các phương tiện đang được theo dõi, hệ thống cắt vùng ảnh phương tiện và chạy mô hình phát hiện biển số YOLOv8-OBb trên từng vùng crop. Kết quả OBb được ánh xạ ngược về hệ tọa độ khung hình gốc, loại bỏ các phát hiện quá nhỏ hoặc không phù hợp, sau đó được nắn chỉnh phối cảnh để tạo ảnh crop biển số đầu vào cho OCR. Cách xử lý theo tầng này giúp giảm nhiễu nền, hạn chế phát hiện nhầm ở các vùng không liên quan và giữ được hình dạng biển số khi xe xuất hiện dưới góc nghiêng.

Sau bước phát hiện biển số, mỗi crop biển số được đưa qua bộ phân loại chất lượng khung hình, gọi là *Quality Router*. Nếu ảnh đủ rõ, hệ thống thực hiện OCR trực tiếp và cập nhật kết quả tạm thời cho track. Nếu ảnh bị mờ, độ phân giải thấp hoặc chưa đủ tin cậy, crop được lưu vào bộ đệm track để chờ các khung hình tốt hơn. Nhờ vậy, hệ thống không ép mô hình OCR phải đưa ra kết luận cuối cùng từ một khung hình xấu.

Khi track kết thúc hoặc khi video được xử lý xong, các kết quả OCR trong bộ đệm được tổng hợp bằng cơ chế đối sánh và bỏ phiếu đa khung hình. Kết quả cuối cùng gồm chuỗi biển số, độ tin cậy, ảnh crop biển số tốt nhất, ảnh phương tiện và danh sách các khung hình evidence. Các bản tin tiến độ và kết quả được gửi về frontend qua SSE, đồng thời được lưu vào MongoDB và Supabase Storage để phục vụ tra cứu lại.



Hình 3.1: Flow chart tổng quan pipeline xử lý nhận dạng biển số trên video

3.2 Thu thập và xử lý dữ liệu

3.2.1 Dữ liệu phát hiện biển số

Tập dữ liệu dùng cho bài toán phát hiện biển số được tổ chức theo định dạng YOLOv8 OBB. Khác với bounding box ngang thông thường, mỗi nhãn trong tập dữ liệu gồm một lớp và bốn điểm của biển số:

```
<class_id> x1 y1 x2 y2 x3 y3 x4 y4
```

Các tọa độ được chuẩn hóa về khoảng $[0, 1]$. Cách biểu diễn này phù hợp với bài toán phát hiện biển số trong video, vì biển số thường bị nghiêng do góc quay camera, hướng di chuyển của phương tiện hoặc phối cảnh đường phố. Việc dùng OBB giúp vùng biển số được bao sát hơn, giảm phần nền thừa khi crop và tạo đầu vào ổn định hơn cho bước OCR phía sau.

Tập dữ liệu được tổng hợp từ nhiều nguồn khác nhau nhằm tăng độ đa dạng về góc nhìn, điều kiện ánh sáng, loại phương tiện và bố cục biển số. Các nguồn chính gồm dữ liệu Kaggle, các frame trích xuất từ video/YouTube, ảnh phương tiện từ Platesmania, và tập UFPR-ALPR. Ngoài ra, tập dữ liệu được bổ sung các mẫu âm tính không chứa biển số để giảm hiện tượng detector phát hiện nhầm biển số ở vùng không chứa biển.

Bảng 3.1: Thống kê dữ liệu phát hiện biển số

Nhóm dữ liệu	Số ảnh	Ghi chú
Platesmania	26.836	Nguồn lớn nhất, ảnh phương tiện thực tế
Kaggle	4.578	Ảnh biển số xe chụp tại các bãi đỗ xe
Các nguồn video	2.851	Frame trích xuất từ video
UFPR-ALPR	4.500	Dùng để tăng đa dạng hình học cho bài toán định vị
Mẫu âm tính	1.700	Ảnh không chứa biển số, dùng để giảm false positive

Tổng cộng, tập dữ liệu gồm 40.465 ảnh và 48.431 nhãn OBB. Dữ liệu được chia thành 33.333 ảnh huấn luyện và 7.132 ảnh kiểm định, tương ứng khoảng 82,4% /

17,6%. Trong toàn bộ tập dữ liệu có 38.261 ảnh có ít nhất một biển số và 2.204 ảnh âm tính với file nhãn rỗng. Các ảnh âm tính này vẫn được giữ lại vì trong hệ thống thực tế, detector thường nhận đầu vào là crop phương tiện hoặc frame video có thể không chứa biển số rõ ràng; nếu chỉ huấn luyện trên ảnh dương tính, mô hình dễ sinh dự đoán sai trên các vùng như đèn xe, logo, mặt ca-lăng hoặc biển quảng cáo.

3.2.2 Dữ liệu nhận diện biển số

Tập dữ liệu dùng cho bài toán OCR biển số gồm hai phần train và valid. Mỗi ảnh là một crop biển số đã được tách khỏi ảnh phương tiện hoặc frame gốc. Nhãn OCR được mã hóa trực tiếp trong tên file: phần trước dấu # là chuỗi biển số, phần sau dấu # là định danh mẫu. Các biển số phần lớn được crop từ ảnh phương tiện thu thập trên Platesmania; phần còn lại đến từ Kaggle.

Ví dụ về tên nhãn dữ liệu:

79A[SEP]122.35#nomer12660750.jpg

30A-827.34#6748.jpg

KP-51-53#6542.jpg

Trong đó, [SEP] biểu diễn điểm ngắt dòng đối với biển số hai dòng. Cách mã hóa này phù hợp với mô hình OCR end-to-end, vì mô hình học trực tiếp ánh xạ từ ảnh crop sang chuỗi ký tự, không cần annotation bounding box cho từng ký tự.

Thống kê tổng quan của tập dữ liệu như sau:

Bảng 3.2: Thống kê tập dữ liệu OCR

Thuộc tính	Số lượng
Tổng số lượng	33.376
Train	27.841
Valid	5.535
Ảnh từ Platesmania	18.925
Ảnh từ Kaggle	14.451
Số chuỗi biển số duy nhất	25.438

Tập dữ liệu có cả biển một dòng và biển hai dòng. Trong đó, biển hai dòng chiếm tỷ lệ lớn hơn:

Bảng 3.3: Thống kê bố cục

Kiểu bố cục	Số ảnh	Tỷ lệ
Một dòng	10.731	32,15%
Hai dòng	22.645	67,85%

Tập ký tự huấn luyện gồm 10 chữ số, các chữ cái Latin viết hoa thường gặp trên biển số Việt Nam, ký tự Đ, và các ký tự phân tách -, ., [SEP].

Ngoài ra, màu nền biển số cũng được ước lượng bằng ngưỡng màu trong không gian HSV trên từng crop OCR. Đây là thống kê sơ bộ:

Bảng 3.4: Thống kê màu nền biển số

Màu nền biển số	Số ảnh	Tỉ lệ
Trắng	24.015	71,09%
Vàng	5.014	14,84%
Xanh dương	3.314	9,81%
Đỏ	1.437	4,25%

3.2.3 Dữ liệu đánh giá chất lượng biển số

Bên cạnh dữ liệu phát hiện và nhận diện ký tự, hệ thống còn sử dụng một tập dữ liệu riêng cho bài toán đánh giá chất lượng ảnh crop biển số. Mục tiêu của mô hình này là ước lượng mức độ đọc được của biển số trước khi đưa ảnh sang OCR hoặc các bước xử lý tăng cường. Việc tách riêng bài toán chất lượng giúp pipeline tránh xử lý mọi crop theo cùng một cách: ảnh rõ có thể được nhận diện trực tiếp, trong khi ảnh mờ, nhỏ hoặc khó đọc có thể được đưa vào nhánh chờ thêm khung hình hoặc nhánh hợp nhất đa khung.

Ở giai đoạn đầu, mô hình được huấn luyện trên dữ liệu LPLCv2 do nhóm tác giả cung cấp. LPLCv2 là tập dữ liệu phân loại độ đọc được của biển số với bốn mức nhãn *perfect*, *good*, *poor* và *illegible*, được xây dựng nhằm đánh giá không chỉ chất lượng ảnh nói chung mà trực tiếp là khả năng đọc ký tự trên biển số [12]. Từ dữ liệu gốc, luận văn tạo bản dùng huấn luyện theo bốn lớp chất lượng và chia thành hai tập *train/valid* để huấn luyện mô hình ban đầu.

Bảng 3.5: Thống kê dữ liệu đánh giá chất lượng biển số

Tập dữ liệu	Train	Valid	Tổng số ảnh
LPLCv2-quality	39.767	14.876	54.643
Fine-tune nội bộ	24.796	5.993	30.789

Sau khi có mô hình khởi tạo từ LPLCv2, luận văn fine-tune thêm trên tập dữ liệu nội bộ được gom từ các crop biển số gần với miền dữ liệu của hệ thống hơn. Các ảnh này vẫn được tổ chức theo cùng bốn mức chất lượng, nhờ đó mô hình giữ được định nghĩa nhãn nhất quán nhưng thích nghi tốt hơn với ảnh biển số Việt Nam, điều kiện camera thực tế và các lỗi thường gặp trong pipeline như crop lệch, nhòe chuyển động hoặc biển số quá nhỏ.

Bảng 3.6: Phân bố nhãn trong dữ liệu chất lượng

Tập dữ liệu	Perfect	Good	Poor	Illegible
LPLCv2-quality	24.271	13.458	9.898	7.016
Fine-tune nội bộ	7.117	12.198	10.130	1.344

3.3 Huấn luyện mô hình

3.3.1 Mô hình nhận diện phương tiện

Trong hệ thống đề xuất, bước nhận diện phương tiện đóng vai trò tiền xử lý quan trọng nhằm xác định và định vị các đối tượng phương tiện giao thông trong khung hình trước khi tiến hành trích xuất biển số. Để thực hiện bước này, luận văn kế thừa và sử dụng bộ trọng số mô hình nhận diện phương tiện được công bố bởi Che et al. trong công trình "Character Time-series Matching for Robust License Plate Recognition" [2].

Trong phạm vi luận văn này, bộ trọng số pretrain Che et al. được sử dụng trực tiếp mà không thực hiện fine-tuning thêm, với mục đích duy nhất là phát hiện phương tiện. Hệ thống cấu hình mô hình để nhận diện sáu lớp phương tiện phù hợp với bối cảnh giao thông Việt Nam, bao gồm: xe máy (class ID 1), xe con (class ID 6), xe tải (class ID 7), xe tải van (class ID 8), xe buýt (class ID 9), và xe ba gác chở hàng (class ID 10). Các lớp này được lọc trực tiếp từ đầu ra của mô hình thông qua danh sách class ID tương ứng ở bước hậu xử lý.

Việc tái sử dụng bộ trọng số này mang lại hai lợi thế chính. Thứ nhất, mô hình đã được huấn luyện trực tiếp trên dữ liệu phương tiện Việt Nam thu thập trong điều kiện thực tế, do đó có khả năng thích nghi tốt với đặc thù mật độ giao thông và điều kiện ánh sáng tại Việt Nam. Thứ hai, kiến trúc YOLOv5m với khoảng 21,2 triệu tham số cung cấp sự cân bằng hợp lý giữa độ chính xác và tốc độ suy luận, phù hợp với yêu cầu xử lý video thời gian thực của hệ thống.

3.3.2 Mô hình nhận diện biển số

Mô hình phát hiện biển số được huấn luyện theo tác vụ phát hiện hộp bao có hướng, tương ứng với cấu hình `task=obj` trong Ultralytics. Mô hình được khởi tạo với trọng số ngẫu nhiên theo cơ chế mặc định của Ultralytics/PyTorch, các thiết lập chính của quá trình huấn luyện được trình bày trong Bảng 3.7.

Bảng 3.7: Cấu hình huấn luyện mô hình phát hiện biển số dạng OBB

Nhóm cấu hình	Giá trị
Tác vụ	task=obb
Checkpoint khởi tạo	Khởi tạo ngẫu nhiên
Kích thước ảnh đầu vào	640 × 640
Số epoch	50
Batch size	8
Thiết bị huấn luyện	GPU, device=0
Số workers	8
AMP	True
Thiết lập tái lập	seed=0, deterministic=True
Bộ tối ưu	auto
Learning rate	lr0=0.001, lrf=0.01
Momentum và weight decay	momentum=0.937, weight_decay=0.0005
Warm-up	warmup_epochs=3, warmup_momentum=0.8, warmup_bias_lr=0.1
Trọng số loss	box=7.5, cls=0.5, dfl=1.5, angle=1.0
Tăng cường dữ liệu	hsv_h=0.015, hsv_s=0.7, hsv_v=0.4, translate=0.1, scale=0.5, flipplr=0.5, mosaic=1.0
Các phép không sử dụng	mixup, cutmix, copy_paste, flipud, shear, perspective
Close mosaic	close_mosaic=10

Các thiết lập trên được lựa chọn nhằm cân bằng giữa độ chính xác phát hiện và chi phí huấn luyện. Trong đó, các trọng số loss box, cls, dfl và angle phản ánh đặc thù của bài toán phát hiện hộp bao có hướng, còn các phép tăng cường dữ liệu như biến đổi màu sắc, tịnh tiến, co giãn và mosaic giúp mô hình thích nghi tốt hơn với sự thay đổi về điều kiện chiếu sáng, góc nhìn và kích thước biển số trong ảnh thực tế.

3.3.3 Thuật toán tracking

Trong pipeline đề xuất, BoT-SORT [4] được đặt sau bước phát hiện phương tiện và trước bước phát hiện biển số. Mỗi hộp bao phương tiện được gán một *track id*; toàn bộ crop biển số và kết quả OCR sau đó được quy về track này. Hệ thống cấu hình tracking theo hướng ưu tiên giữ ổn định định danh: phát hiện tin cậy cao dùng để cập nhật track chắc chắn, còn phát hiện yếu hơn vẫn được xét để khôi phục track khi xe bị mờ, lóa hoặc che khuất ngắn. Sau khi có hộp bao xe, hệ thống cắt vùng phương tiện thay vì chạy phát hiện biển số trên toàn ảnh; vùng cắt được mở rộng thêm một biên nhỏ để tránh mất biển số ở đầu hoặc đuôi xe.

Trên crop phương tiện, detector biển số OBB trả về vùng biển số và bốn điểm

góc được ánh xạ ngược về hệ tọa độ khung hình gốc. Liên kết biển số–phương tiện không được chốt từ một khung hình, mà được bỏ phiếu qua nhiều khung hình liên tiếp. Mỗi biển số có một định danh ngắn hạn dựa trên vị trí, khoảng cách tâm, kích thước và phương tiện chứa nó. Liên kết chỉ được khóa khi cùng một biển số nghiêng ổn định về cùng một track với tỷ lệ đồng thuận đủ lớn. Sau khi khóa, nếu tâm biển số liên tục không nằm trong vùng phương tiện tương ứng, liên kết bị hủy để tránh kéo sai biển số sang xe khác.

Mỗi track có một bộ đệm lưu các crop biển số theo thời gian. Khi bộ đệm đầy, hệ thống không chỉ giữ frame sắc nét nhất mà xếp hạng crop bằng điểm:

$$S = q \times \max(p_{ocr}, 0.10)$$

trong đó q là điểm chất lượng thị giác và p_{ocr} là độ tin cậy trung bình của OCR nếu crop đã được đọc. Cách xếp hạng này ưu tiên frame vừa rõ, vừa có bằng chứng nhận dạng đáng tin cậy. Track được chốt khi phương tiện biến mất trong một số bước liên tiếp, hoặc khi đã có kết quả OCR đủ tin cậy. Các track quá ngắn hoặc không có liên kết biển số ổn định bị loại khỏi kết quả cuối.

Lý luận lựa chọn. Hệ thống chọn track phương tiện làm trực thời gian vì phương tiện lớn hơn biển số, xuất hiện ổn định hơn và có nhiều đặc trưng ngoại hình để BoT-SORT duy trì định danh. Biển số nhỏ, dễ mất nét, bị lóa hoặc bị che; nếu tracking trực tiếp biển số, chỉ vài khung hình xấu đã có thể làm đứt quỹ đạo. Vì vậy, biển số được xem như quan sát gắn vào track phương tiện.

Việc bỏ phiếu đa khung là cần thiết vì quyết định một khung hình dễ sai trong cảnh đông xe. Khi hai phương tiện đi sát nhau, biển số có thể nằm gần biên nhiều hộp phương tiện hoặc bị detector trả về lệch nhẹ. Bỏ phiếu giúp hệ thống chỉ khóa liên kết khi quan hệ đó đủ nhất quán, đồng thời vẫn cho phép hủy nếu bằng chứng về sau cho thấy liên kết ban đầu không còn hợp lệ.

3.3.4 Mô hình phân loại chất lượng

Phương pháp. Mô hình phân loại chất lượng được thiết kế như một bộ định tuyến trước OCR, với nhiệm vụ quyết định một crop biển số nên được đọc ngay, đưa vào tổng hợp đa khung hình hay chỉ lưu làm evidence. Đầu vào của mô hình là ảnh biển số đã được nắn chỉnh phối cảnh. Đầu ra ban đầu là nhãn độ đọc được gồm bốn mức: *perfect*, *good*, *poor* và *illegible*. Hai mức *perfect* và *good* được xem là phù hợp để OCR trực tiếp; hai mức *poor* và *illegible* được xem là không phù hợp cho quyết định nhận dạng một khung hình.

Từ nhãn bốn lớp, hệ thống suy ra ba hướng xử lý. Với ảnh *perfect* hoặc *good*,

crop được đưa vào OCR ngay trong khung hình hiện tại. Nếu kết quả OCR sau chuẩn hóa và sửa lỗi ký tự đạt ngưỡng tin cậy, track có thể phát ra kết quả tạm thời sớm. Với ảnh *poor*, hệ thống không loại bỏ crop, mà đưa crop vào bộ đệm để chờ tổng hợp với các khung hình khác. Với ảnh *illegible*, hoặc khi ảnh bị chẩn đoán là che khuất nặng, crop chỉ được lưu làm bằng chứng và không ép OCR đưa ra dự đoán. Cách phân luồng này giúp giảm lỗi “đoán mò” của OCR trên ảnh quá xấu, đồng thời vẫn tận dụng được những frame chưa đủ tốt nhưng còn chứa thông tin ký tự.

Bên cạnh xác suất phân loại, hệ thống tính thêm một điểm chất lượng liên tục $q \in [0, 1]$ cho mỗi crop:

$$q = 0.80 \times \min\left(\frac{\text{Var}(\nabla^2 I)}{500}, 1\right) + 0.20 \times \min\left(\frac{h \times w}{A_{\text{ref}}}, 1\right)$$

trong đó $\text{Var}(\nabla^2 I)$ là phương sai Laplacian trên ảnh xám, h và w là chiều cao và chiều rộng crop, còn A_{ref} là diện tích tham chiếu. Các hằng số trong công thức này là siêu tham số được đặt thủ công trong quá trình thiết kế pipeline, không phải tham số được học từ dữ liệu. Trọng số 0.80/0.20 phản ánh giả định rằng độ sắc nét của biên ký tự quan trọng hơn kích thước crop đối với khả năng đọc biển số; thành phần diện tích chỉ đóng vai trò phụ để phạt các crop quá nhỏ, thiếu thông tin. Ngưỡng chuẩn hóa 500 là trần cho phương sai Laplacian: khi $\text{Var}(\nabla^2 I) \geq 500$, crop được xem là đủ sắc theo thang điểm này và thành phần sắc nét được chặn ở 1 để tránh nhiễu hoặc cạnh nền làm tăng điểm quá mức. Trong cài đặt của đồ án, kích thước biển số tối thiểu trước padding là 30×10 pixel và diện tích tham chiếu được lấy bằng $A_{\text{ref}} = 9 \times 30 \times 10 = 2700 \text{ pixel}^2$, tương ứng với việc một crop có diện tích khoảng ba lần theo mỗi chiều so với ngưỡng tối thiểu sẽ đạt điểm kích thước tối đa.

Cần phân biệt q với quyết định định tuyến chính của mô hình. Khi có classifier học sâu, ba hướng xử lý được quyết định bởi nhãn độ đọc được: *perfect/good* $\rightarrow$ *direct*, *poor* $\rightarrow$ *tracklet_fusion*, còn *illegible* hoặc crop bị che khuất nặng $\rightarrow$ *unreadable_wait*. Điểm q không tự đặt ngưỡng cho ba nhánh này, mà được lưu như tín hiệu chất lượng số để chọn ảnh đại diện và xếp hạng frame trong bộ đệm theo điểm $S = q \times \max(p_{\text{ocr}}, 0.10)$. Chỉ trong chế độ dự phòng khi không có classifier, q mới được dùng trực tiếp để suy ra nhãn: $q < 0.08$ hoặc che khuất nặng được xem là *illegible*; nếu không có dấu hiệu suy giảm rõ rệt, $q \geq 0.70$ được xem là *perfect*, $q \geq 0.35$ được xem là *good*, các trường hợp còn lại được xem là *poor*. Ngay cả với nhánh *direct*, kết quả OCR vẫn chỉ được chấp nhận sớm khi chuỗi sau chuẩn hóa hợp lệ và độ tin cậy đạt ngưỡng 0.90; nếu không, crop được chuyển về bộ đệm để tổng hợp theo track.


Mô hình học sâu được huấn luyện theo bài toán phân loại ảnh nhẹ, sử dụng backbone YOLOv8n-cls khởi tạo từ trọng số đã huấn luyện trước. Ảnh đầu vào được resize về kích thước nhỏ để giữ tốc độ suy luận phù hợp với pipeline video. Trong quá trình huấn luyện, các phép tăng cường như thay đổi màu sắc, dịch chuyển, co giãn, lật ngang, auto-augment và random erasing được sử dụng để mô phỏng biến động ánh sáng, sai số crop và suy giảm cục bộ của biến số trong video thực tế. Bộ tối ưu, momentum, weight decay, AMP và seed được giữ nhất quán với các thí nghiệm YOLO khác để dễ tái lập.

3.3.5 Kiến trúc và huấn luyện mô hình OCR (SmallLPR-Line-CTC)

Hạn chế của LPRNet gốc với bài toán biển số Việt Nam. Khối OCR trong hệ thống được xây dựng từ tinh thần của LPRNet: nhận dạng trực tiếp toàn bộ ảnh biển số bằng CNN nhẹ kết hợp CTC, không cần tách ký tự thủ công [6]. Cách tiếp cận này phù hợp với pipeline video vì tốc độ nhanh và yêu cầu nhãn đơn giản, chỉ cần chuỗi ký tự của biển số. Tuy nhiên, khi áp dụng cho biển số Việt Nam, LPRNet gốc bộc lộ bốn hạn chế chính. Thứ nhất, ảnh crop từ video thường bị nghiêng, lệch phối cảnh hoặc không nằm chính giữa, trong khi mô hình gốc không có cơ chế căn chỉnh hình học đủ rõ ở phần backbone chính. Thứ hai, các khối tích chập nhẹ của LPRNet ưu tiên tốc độ nhưng chưa khai thác tốt đồng thời nét ký tự nhỏ, nhiễu cục bộ và ngữ cảnh rộng hơn quanh từng ký tự. Thứ ba, việc đọc đặc trưng như một chuỗi một chiều làm suy giảm thông tin vị trí theo chiều dọc, trong khi biển số Việt Nam có cả bố cục một dòng và hai dòng. Thứ tư, một head CTC duy nhất buộc mọi bố cục phải đi qua cùng một dòng giải mã, khiến biển hai dòng dễ bị đọc sai thứ tự hoặc ghép nhầm giữa dòng trên và dòng dưới.

Từ các hạn chế trên, đề án đề xuất SmallLPR-Line-CTC như một biến thể cải tiến của LPRNet cho bối cảnh biển số Việt Nam. Mô hình vẫn giữ các ưu điểm quan trọng của LPRNet: nhận dạng không cần phân đoạn ký tự, huấn luyện end-to-end bằng CTC và suy luận trong một lần lan truyền tiến. Điểm khác biệt nằm ở việc bổ sung các cơ chế căn chỉnh, trích đặc trưng đa tỷ lệ, bảo toàn bố cục hai chiều và định tuyến CTC theo bố cục dòng.

Tổng quan SmallLPR-Line-CTC. Tổng quát, luồng xử lý của mô hình là:



Hình 3.2: Kiến trúc tổng quát của mô hình OCR biến số

Trong đó I là ảnh crop biến số đã resize về 48×96 . Ảnh đầu vào trước hết đi qua STN để giảm sai lệch hình học, sau đó được mã hóa bởi backbone CNN cải tiến từ khối nhẹ của LPRNet. Khác với hướng chuyển ngay đặc trưng thành chuỗi một chiều, mô hình giữ feature map ở dạng hai chiều 6×12 , chiếu về không gian đặc trưng 256 chiều và cộng mã hóa vị trí theo hàng/cột. Từ biểu diễn này, các head CTC được tách theo vai trò: `global_head` học tín hiệu nhận dạng toàn cục, `one_line_head` đọc biến một dòng, `top_head` và `bottom_head` đọc riêng hai dòng, còn `layout_head` dự đoán bố cục để chọn đường giải mã phù hợp ở giai đoạn suy luận. Mô hình không sử dụng bounding box ký tự, không tách ký tự trước và cũng không cần annotation vị trí dòng.

Bảng 3.8: Kiến trúc STN alignment network

Layer	Tham số	Kích thước đầu ra
Input	RGB image	$3 \times 48 \times 96$
Conv	$3 \times 3, 3 \rightarrow 32$	$32 \times 46 \times 94$
MaxPool + Mish	2×2	$32 \times 23 \times 47$
Conv	$5 \times 5, 32 \rightarrow 32$	$32 \times 19 \times 43$
MaxPool + Mish	3×3	$32 \times 6 \times 14$
FC + Mish	$2688 \rightarrow 32$	32
FC	$32 \rightarrow 6$	affine 2×3

STN để bù sai lệch hình học. Hạn chế đầu tiên của LPRNet gốc trong pipeline video là ảnh biến số hiếm khi ở trạng thái đã căn chỉnh lý tưởng: hộp crop có thể lệch tâm, méo nhẹ do góc nhìn, hoặc bị xoay do phương tiện di chuyển. Các sai lệch này làm cho cùng một ký tự xuất hiện ở nhiều tư thế khác nhau, khiến backbone phải tự học cả bài toán căn chỉnh lẫn bài toán nhận dạng. Vì vậy, `SmallLPR-Line-CTC` đặt một Spatial Transformer Network ở đầu mô hình. Theo cách tiếp cận của STN, một mạng con có thể dự đoán phép biến đổi không gian khả vi và được huấn luyện end-to-end cùng mạng chính [13].

Trong đồ án, STN dự đoán ma trận affine 2×3 gồm sáu tham số để biến đổi ảnh biến số trước khi đưa vào backbone. Tầng fully connected cuối được khởi tạo thành phép biến đổi đồng nhất, nên ở đầu huấn luyện mô hình không làm biến dạng ảnh. Khi dữ liệu cho thấy việc dịch chuyển, xoay hoặc co giãn nhẹ giúp giảm CTC loss, STN tự học phép hiệu chỉnh tương ứng. Cách này giữ pipeline đơn giản hơn so với tiền xử lý hình học thủ công, đồng thời tránh phụ thuộc vào các giả định cứng về góc nghiêng của biến số.

Bảng 3.9: Khối cơ bản `SmallBasicBlockCBAM`

Thành phần	Mô tả
MixConv	Trích xuất đặc trưng bằng nhiều kernel, $C_{in} \rightarrow C_{out}/4$
Conv 3×1	Khai thác nét dọc của ký tự
Conv 1×3	Khai thác nét ngang và quan hệ ký tự theo chiều biến
Conv 1×1	Khôi phục số kênh về C_{out}
BatchNorm + Mish	Ổn định huấn luyện và tăng phi tuyến
CBAM	Tái trọng số đặc trưng theo kênh và không gian
Residual	Dùng khi $C_{in} = C_{out}$

SmallBasicBlockCBAM để tăng năng lực trích đặc trưng. LPRNet gốc sử dụng các khối tích chập nhẹ để đạt tốc độ thời gian thực, nhưng thiết kế này dễ bị hạn chế khi ký tự nhỏ, bị mờ hoặc có nét gần nhau. Với ảnh biến số kích thước thấp, cùng một vùng ký tự cần được nhìn ở nhiều thang ngữ cảnh: kernel nhỏ giúp giữ nét mảnh như cạnh chữ và số, trong khi kernel lớn hơn giúp quan sát quan hệ giữa các nét hoặc giữa ký tự và nền biến. Vì vậy, khối `SmallBasicBlockCBAM` thay phần tích chập đầu bằng MixConv, trong đó các nhóm kênh sử dụng nhiều kích thước kernel khác nhau để khai thác các mẫu ở nhiều độ phân giải [14].

Sau khi trích đặc trưng đa tỷ lệ, CBAM được thêm vào cuối block để tái trọng số đặc trưng theo kênh và theo không gian [15]. Về mặt trực giác, attention theo kênh giúp mô hình chọn nhóm đặc trưng hữu ích cho nét ký tự, còn attention theo không gian giúp tăng trọng số các vùng chứa ký tự so với nền, vít, khung biến hoặc nhiễu do crop. Như vậy, backbone vẫn giữ tinh thần nhỏ gọn của LPRNet nhưng được tăng khả năng phân biệt chi tiết ký tự trong các điều kiện video không ổn định.

Bảng 3.10: Backbone CNN của SmallLPR-Line-CTC

Layer	Tham số	Kích thước đầu ra
Input	RGB image	$3 \times 48 \times 96$
Stem	Conv 3×3 , $3 \rightarrow 64$ + BN + Mish	$64 \times 48 \times 96$
Stage 1	SmallBasicBlockCBAM(64, 128) + MaxPool2	$128 \times 24 \times 48$
Stage 2	SmallBasicBlockCBAM(128, 256)	$256 \times 24 \times 48$
	SmallBasicBlockCBAM(256, 256) + MaxPool2	$256 \times 12 \times 24$
Stage 3	SmallBasicBlockCBAM(256, 256)	$256 \times 12 \times 24$
	SmallBasicBlockCBAM(256, 256) + MaxPool2	$256 \times 6 \times 12$
Projection	Conv 1×1 , $256 \rightarrow 256$	$256 \times 6 \times 12$
2D positional encoding	row embedding + column embedding	$6 \times 12 \times 256$

Feature map hai chiều và positional encoding. Một điểm khác biệt quan trọng so với LPRNet gốc là mô hình không ép feature map thành chuỗi một chiều ngay sau backbone. Trong LPRNet, cách đọc theo chuỗi ngang phù hợp với giả định biển số chủ yếu là một dòng; tuy nhiên với biển số Việt Nam, tọa độ theo chiều dọc mang thông tin ngữ nghĩa rõ ràng: cùng một cột ảnh có thể chứa ký tự thuộc dòng trên hoặc dòng dưới. Nếu làm phẳng quá sớm, mô hình phải suy ra bố cục hai dòng từ một chuỗi đã mất cấu trúc hàng/cột, dẫn đến nguy cơ đảo thứ tự đọc hoặc trộn ký tự giữa hai dòng.

Vì vậy, SmallLPR-Line-CTC giữ đặc trưng ở dạng 6×12 sau backbone. Sau lớp projection 1×1 , mỗi vị trí không gian được cộng mã hóa vị trí hai chiều gồm embedding theo hàng và embedding theo cột. Biểu diễn này cho phép mô hình biết một đặc trưng nằm ở dòng nào và cột nào trên biển số, nhưng vẫn giữ khả năng học mềm thay vì áp đặt quy tắc tách dòng cố định. Đây là nền tảng để các nhánh attention phía sau gom đặc trưng theo một dòng hoặc hai dòng mà không cần detector dòng riêng.

Bảng 3.11: Các head nhận dạng và bố cục

Head	Đầu vào	Đầu ra	Vai trò
global_head	flatten 6×12	$72 \times V $	CTC toàn cục trên cả biển
one_line_attention	$6 \times 12 \times 256$	attention 6×12	Gom đặc trưng cho biển một dòng
one_line_head	sequence 16 bước	$16 \times V $	CTC cho biển một dòng
line_attention	$6 \times 12 \times 256$	2 attention maps	Tách mềm dòng trên/dòng dưới
top_head	sequence 12 bước	$12 \times V $	CTC dòng trên
bottom_head	sequence 12 bước	$12 \times V $	CTC dòng dưới
layout_head	global average pooled feature	2 logits	Phân loại một dòng/hai dòng

Multi-head CTC theo bố cục. Đóng góp quan trọng nhất của SmallLPR-Line-CTC nằm ở cách thay một head CTC duy nhất của LPRNet bằng nhiều head chuyên biệt theo bố cục. Nếu chỉ dùng một chuỗi CTC toàn cục, mô hình phải học đồng thời hai quy ước đọc khác nhau: đọc liên tục từ trái sang phải với biển một dòng, và đọc dòng trên trước rồi dòng dưới sau với biển hai dòng. Điều này làm bài toán căn hàng của CTC trở nên nhập nhằng, đặc biệt khi hai dòng có độ dài khác nhau hoặc khi khoảng cách giữa các ký tự không đều.

Trong thiết kế đề xuất, global_head vẫn được giữ như một nhánh phụ trợ để học biểu diễn toàn cục trên toàn bộ feature map. Với biển một dòng, one_line_attention gom mềm đặc trưng theo chiều dọc thành một chuỗi 16 bước và one_line_head thực hiện CTC trên chuỗi này. Với biển hai dòng, line_attention sinh hai attention map tương ứng với dòng trên và dòng dưới; mỗi dòng sau đó được đọc bởi một head CTC riêng. Mô hình bổ sung *vertical prior* để khuyến khích attention của dòng trên tập trung vào nửa trên feature map và attention của dòng dưới tập trung vào nửa dưới, nhưng đây chỉ là thiên hướng mềm, không phải luật cắt dòng cố định.

Ở giai đoạn suy luận, layout_head quyết định ảnh đầu vào thuộc dạng một dòng hay hai dòng. Nếu xác suất của lớp hai dòng lớn hơn ngưỡng 0.5, hệ thống giải mã riêng dòng trên bằng top_head, dòng dưới bằng bottom_head, sau đó ghép hai chuỗi bằng token [SEP]. Nếu không, kết quả được lấy từ one_line_head. Nhờ cách định tuyến này, cùng một mô hình xử lý được cả hai bố cục biển số mà không cần detector dòng hoặc annotation bounding box ký tự.

Hàm mất mát huấn luyện. Do kiến trúc được tách thành nhiều head theo bố

cục, quá trình huấn luyện cũng được xây dựng dưới dạng bài toán đa nhiệm. So với LPRNet gốc, nơi mục tiêu chính là tối ưu một chuỗi CTC, mô hình đề xuất cần đồng thời học ba loại tín hiệu: chuỗi ký tự toàn cục, chuỗi ký tự theo từng bố cục dòng và nhãn phân loại bố cục. Vì vậy, hàm mất mát tổng hợp gồm CTC loss cho các nhánh nhận dạng và cross-entropy loss cho `layout_head`.

Với mỗi ảnh đầu vào, `global_head` luôn được huấn luyện trên toàn bộ chuỗi biển số để giữ tín hiệu nhận dạng chung. Nếu ảnh là biển một dòng, `one_line_head` học chuỗi ký tự đầy đủ. Nếu ảnh là biển hai dòng, nhãn được tách thành hai phần bởi token `[SEP]`, trong đó `top_head` học chuỗi dòng trên và `bottom_head` học chuỗi dòng dưới. Cách tổ chức này biến bố cục từ một yếu tố gây nhiễu thành tín hiệu giám sát trực tiếp, giúp mỗi head học đúng kiểu căn hàng mà nó sẽ sử dụng khi suy luận.

Hàm mất mát tổng quát được định nghĩa như sau:

$$\mathcal{L} = \lambda_g \mathcal{L}_{global} + \lambda_1 \mathcal{L}_{one} + \lambda_t \mathcal{L}_{top} + \lambda_b \mathcal{L}_{bottom} + \lambda_l \mathcal{L}_{layout}$$

Trong đó $\mathcal{L}_{global}$, $\mathcal{L}_{one}$, $\mathcal{L}_{top}$ và $\mathcal{L}_{bottom}$ là CTC loss của các nhánh nhận dạng tương ứng. Thành phần $\mathcal{L}_{layout}$ là cross-entropy loss dùng để phân loại ảnh biển số thành hai lớp: một dòng hoặc hai dòng.

Trong cấu hình huấn luyện, các trọng số được đặt là:

$$\lambda_g = 1.0, \quad \lambda_1 = 1.0, \quad \lambda_t = 1.0, \quad \lambda_b = 1.0, \quad \lambda_l = 0.2$$

Việc đặt trọng số nhỏ hơn cho $\mathcal{L}_{layout}$ phản ánh vai trò phụ trợ của nhánh bố cục. Nhiệm vụ chính của mô hình vẫn là nhận dạng chính xác chuỗi ký tự, trong khi nhánh bố cục cung cấp tín hiệu điều hướng để chọn cơ chế giải mã phù hợp ở giai đoạn suy luận.

CTC loss được sử dụng vì nhãn huấn luyện chỉ có chuỗi ký tự biển số, không có vị trí chính xác của từng ký tự trên ảnh. Với mỗi nhánh CTC, mô hình sinh ra một chuỗi phân phối xác suất theo thời gian. CTC tự động xét các khả năng căn hàng giữa chuỗi dự đoán và chuỗi nhãn, sau đó tối ưu xác suất của nhãn đúng bằng cách cho phép xuất hiện token rỗng `<blank>` và các token lặp. Nhờ đó, mô hình có thể học OCR end-to-end mà không cần annotation ký tự hoặc bước tách ký tự thủ công.

Đối với các nhánh chuyên biệt, loss được mask theo bố cục của từng mẫu. Biển một dòng chỉ đóng góp vào `one_line_head`, còn biển hai dòng chỉ đóng góp

vào `top_head` và `bottom_head`. Nhánh `global_head` và `layout_head` được huấn luyện trên cả hai loại mẫu. Cơ chế mask này giúp tránh việc ép một nhánh học những trường hợp không phù hợp với chức năng của nó, đồng thời làm cho từng nhánh đảm nhiệm một vai trò rõ ràng trong mô hình.

Chi tiết huấn luyện Mô hình `SmallLPR-Line-CTC` được huấn luyện bằng PyTorch Lightning trên tập ảnh crop biển số tại `data/datasets/ocr`. Tập dữ liệu được chia thành hai phần: `train` và `valid`. Sau khi loại bỏ các ảnh quá nhỏ và các mẫu đã được đánh dấu lỗi trong quá trình rà soát dữ liệu, tập huấn luyện còn 27.434 ảnh, còn tập validation có 5.527 ảnh. Nhãn OCR được lấy trực tiếp từ tên file ảnh; đối với biển hai dòng, token `[SEP]` được dùng để biểu diễn ranh giới giữa dòng trên và dòng dưới.

Trước khi đưa vào mô hình, mỗi ảnh được resize về kích thước 48×96 bằng cách giữ nguyên tỷ lệ và padding phần còn thiếu. Các ảnh có kích thước nhỏ hơn 20×8 pixel được loại bỏ để tránh đưa vào huấn luyện những mẫu không đủ thông tin ký tự. Giá trị pixel sau đó được chuẩn hóa theo công thức:

$$x' = (x - 127.5) \times 0.0078125$$

Trong quá trình huấn luyện, các phép tăng cường dữ liệu được áp dụng để mô phỏng điều kiện thực tế của ảnh biển số trong video. Cụ thể, ảnh có thể được dịch chuyển, scale, xoay nhẹ, biến đổi phối cảnh, làm mờ chuyển động, làm mờ Gaussian, thêm nhiễu, thay đổi độ sáng, độ tương phản và sắc độ màu. Các phép biến đổi này giúp mô hình ổn định hơn trước sai số crop, rung hình, nhòe chuyển động và thay đổi ánh sáng trong môi trường giao thông.

Mô hình được huấn luyện trong 50 epoch, checkpoint tốt nhất được chọn theo độ chính xác trên tập validation. Quá trình tối ưu sử dụng AdamW với learning rate ban đầu 3×10^{-4} , weight decay 10^{-4} , batch size 64 và gradient clipping bằng 1.0. Learning rate được điều chỉnh bằng cosine annealing scheduler với giá trị nhỏ nhất 10^{-6} .

Trong mỗi epoch, mô hình được đánh giá bằng exact-match accuracy trên toàn bộ chuỗi biển số sau khi decode. Chỉ khi toàn bộ chuỗi dự đoán trùng khớp với nhãn, mẫu đó mới được tính là đúng.

3.4 Xử lý kết quả sau mô hình

Đầu ra thô từ mô hình OCR là một chuỗi các cặp (ký tự, xác suất) — ký hiệu là `char_probs` — tương ứng với từng ký tự được nhận diện trên ảnh biển số. Tuy nhiên, đầu ra này chưa thể được sử dụng trực tiếp do ba lý do chính: (1) một số ký

tự có hình dạng tương đồng dễ bị nhầm lẫn lẫn nhau; (2) một ảnh đơn lẻ thường không đủ tin cậy do biến động về góc chụp, độ mờ và điều kiện ánh sáng; và (3) chuỗi ký tự nhận được chưa chắc tuân theo định dạng biển số hợp lệ của Việt Nam. Mục này mô tả hai lớp hậu xử lý được thực hiện sau khi mô hình trả kết quả: xác thực định dạng biển số và tổng hợp đa khung hình.

3.4.1 Xác thực định dạng biển số

Chuẩn hóa và kiểm tra định dạng Sau khi mô hình OCR trả về chuỗi các cặp (ký tự, xác suất), hệ thống thực hiện một bước chuẩn hóa văn bản nhằm đưa kết quả về dạng thống nhất trước khi kiểm tra định dạng biển số. Cụ thể, chuỗi đầu ra được loại bỏ các khoảng trắng dư thừa, chuyển toàn bộ ký tự chữ cái về dạng in hoa, chuẩn hóa ký hiệu phân tách giữa các dòng của biển số thành khoảng trắng.

Sau khi chuẩn hóa, chuỗi biển số được đối sánh với một tập các mẫu định dạng biển số Việt Nam được xây dựng trước. Tập mẫu này bao gồm nhiều nhóm định dạng phổ biến, chẳng hạn biển xe máy, biển ô tô, biển quân sự và một số loại biển số đặc biệt. Mỗi mẫu định dạng được mô tả dựa trên cấu trúc vị trí của chữ số, chữ cái và ký tự có thể là chữ hoặc số. Trong đó, chữ số đại diện cho các mã tỉnh, số seri hoặc phần định danh; chữ cái thường xuất hiện trong nhóm seri; còn một số vị trí đặc biệt có thể chấp nhận cả chữ cái và chữ số tùy theo loại biển.

Sửa lỗi ký tự mơ hồ theo slot Song song với bước kiểm tra định dạng, hệ thống còn thực hiện hiệu chỉnh các nhầm lẫn ký tự đặc trưng của OCR tiếng Việt. Nguyên nhân của những nhầm lẫn này là sự tương đồng hình dạng giữa một số cặp ký tự, ví dụ O/0, I/1, S/5, B/8, G/6, Z/2. Thay vì áp dụng một bảng thay thế toàn cục, hệ thống thực hiện hiệu chỉnh có nhận thức về ngữ cảnh vị trí (slot-aware): mỗi ký tự trong chuỗi đầu ra được căn chỉnh vào đúng vị trí slot tương ứng trong mẫu biển số, và việc sửa chữa chỉ được thực hiện khi loại ký tự tại slot đó không khớp — ví dụ, slot D (digit) nhận chữ cái O sẽ được sửa thành 0, còn slot L (letter) nhận chữ số 0 sẽ được sửa thành O.

Quá trình căn chỉnh sử dụng giải thuật quy hoạch động với ba thao tác: khớp (align), bỏ qua token đầu vào (skip) và chèn token còn thiếu (missing), tương tự cơ chế edit-distance. Chi phí của từng thao tác được thiết kế bất đối xứng để ưu tiên các sửa đổi có chi phí thấp (chỉ cần đổi loại ký tự) hơn là xóa hay thêm ký tự. Sau căn chỉnh, mỗi sửa đổi làm giảm xác suất của ký tự đó đi một hệ số 0.92 để phản ánh sự không chắc chắn. Hệ thống thử căn chỉnh với tất cả 35 mẫu biển số và chọn mẫu có tổng chi phí căn chỉnh thấp nhất làm kết quả cuối cùng.

3.4.2 Tổng hợp đa khung hình

Cơ chế định tuyến theo chất lượng ảnh Không phải mọi khung hình đều có chất lượng đủ để OCR ngay lập tức. Mỗi ảnh cắt biển số được đưa qua bộ định tuyến chất lượng trước khi quyết định xử lý. Bộ định tuyến phân loại ảnh thành ba hướng xử lý: `direct` — ảnh đủ rõ để OCR ngay trong khung hình hiện tại; `tracklet_fusion` — ảnh chưa đủ chất lượng, được đưa vào bộ đệm track để tổng hợp sau; và `unreadable_wait` — ảnh quá mờ hoặc bị che khuất, chỉ được lưu làm bằng chứng mà không chạy OCR. Đối với hướng `direct`, nếu kết quả OCR sau sửa lỗi đạt ngưỡng xác suất ($\text{CONF_THRESHOLD} = 0.90$) và thỏa mãn định dạng Việt Nam, ký quả được chấp nhận ngay. Trong trường hợp ngược lại, ảnh vẫn được đưa vào bộ đệm track để tích lũy thêm bằng chứng từ các khung hình tiếp theo.

Ngoài ra, đối với ảnh thuộc hướng `tracklet_fusion`, hệ thống sinh thêm các phiên bản tiền xử lý tăng cường khác nhau tùy theo nhãn suy giảm chất lượng được phát hiện (`DegradationTags`). Cụ thể, ảnh bị mờ chuyển động hoặc độ phân giải thấp được làm sắc nét bằng `unsharp masking`; ảnh thiếu sáng được điều chỉnh `gamma`; ảnh tương phản thấp được tăng cường bằng `CLAHE` trên kênh độ sáng `L` của không gian màu `LAB`; ảnh có nhiều mưa hoặc sương được lọc bằng `bilateral filter`. Mỗi phiên bản tăng cường này được đưa qua OCR độc lập, sau đó được xếp hạng lại bằng hàm `rerank`, trong đó điểm của mỗi ứng viên được tính dựa trên xác suất trung bình ký tự, tính hợp lệ định dạng, chi phí sửa lỗi và phương pháp tiền xử lý được dùng.

Tổng hợp kết quả theo track Khi một track phương tiện kết thúc, tức là phương tiện rời khỏi khung hình hoặc video đã được xử lý đến khung hình cuối cùng, hệ thống tiến hành tổng hợp toàn bộ bằng chứng nhận dạng ký tự đã thu thập được trong suốt thời gian tồn tại của track. Toàn bộ các khung hình thuộc track đều được đưa vào quá trình tổng hợp nhằm tận dụng tối đa thông tin quan sát theo thời gian.

Bước tổng hợp kết quả OCR sử dụng cơ chế `Character Time-series Matching`, cải tiến dựa trên đề xuất của Che [2]. Thay vì biểu quyết trực tiếp trên toàn bộ chuỗi biển số, hệ thống thực hiện biểu quyết độc lập theo từng vị trí ký tự. Với mỗi khung hình, kết quả xác suất ký tự từ mô hình OCR được căn chỉnh vào mẫu biển số phù hợp nhất bằng giải thuật quy hoạch động như đã trình bày ở mục 3.4.1. Sau bước căn chỉnh, mỗi vị trí ký tự nhận được một phiếu bầu tương ứng với ký tự được dự đoán tại vị trí đó trong từng khung hình.

Đối với mỗi vị trí ký tự, hệ thống chọn ký tự có tổng số phiếu bầu cao nhất làm kết quả đại diện. Tuy nhiên, ký tự này chỉ được chấp nhận nếu đồng thời thỏa mãn


hai điều kiện: tỷ lệ phiếu bầu đạt ít nhất 0,5 và xác suất trung bình của ký tự đạt ít nhất 0,50. Những vị trí không thỏa mãn các điều kiện trên được xem là chưa xác định và được gán ký hiệu “?”.

Kết quả tổng hợp của một track chỉ được chấp nhận khi tất cả các vị trí ký tự đều đã xác định và chuỗi biển số sau tổng hợp thỏa mãn định dạng biển số Việt Nam hợp lệ. Trong các trường hợp còn lại, track bị từ chối và hệ thống ghi nhận nguyên nhân tương ứng, bao gồm: còn tồn tại vị trí ký tự chưa phân giải, chuỗi biển số không đúng định dạng, hoặc không có bằng chứng OCR để tổng hợp.

CHƯƠNG 4. XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG

4.1 Yêu cầu và kiến trúc tổng quan

4.1.1 Sơ đồ use case



Hình 4.1: Sơ đồ use case tổng quan

Tác nhân tham gia Hệ thống có một tác nhân duy nhất là Người dùng đại diện cho bất kỳ cá nhân nào truy cập hệ thống qua giao diện web. Tác nhân này đóng hai vai trò tùy theo trạng thái xác thực: với các chức năng quản lý tài khoản, người dùng là khách chưa được xác thực; với các chức năng nghiệp vụ chính như xử lý video, phân tích sự kiện từ video, người dùng phải đã đăng nhập hợp lệ. Hệ thống không phân biệt vai trò theo nhóm quyền mà kiểm soát truy cập hoàn toàn dựa trên phiên đăng nhập.

Các use case chính Hệ thống có bảy use case chia thành hai nhóm chức năng.


Nhóm quản lý tài khoản gồm ba use case. *Đăng ký* cho phép người dùng tạo tài khoản mới; hệ thống xác thực dữ liệu đầu vào, băm mật khẩu và lưu thông tin vào cơ sở dữ liệu. *Đăng nhập* cho phép người dùng xác thực danh tính và nhận token bảo mật để truy cập các chức năng được bảo vệ. *Đăng xuất* hủy phiên làm việc hiện tại và đưa người dùng về trạng thái khách.

Nhóm nghiệp vụ nhận dạng gồm bốn use case, chỉ khả dụng sau khi đăng nhập. *Xử lý toàn bộ video tải lên* là luồng xử lý chính: người dùng tải lên một tệp video hoàn chỉnh, hệ thống chạy pipeline ALPR trên toàn bộ nội dung video và trả tiến độ, kết quả nhận dạng về giao diện theo thời gian thực. *Chọn trích đoạn để xử lý* phục vụ trường hợp người dùng chỉ cần phân tích một khoảng thời gian cụ thể từ nguồn camera trực tiếp hoặc từ video đã tải lên. Trong luồng này, người dùng chọn nguồn video, đánh dấu đoạn thời gian cần xử lý, sau đó backend trích xuất các khung hình tương ứng và chạy pipeline nhận dạng trên cửa sổ thời gian đã chọn. *Xem kết quả và minh chứng nhận dạng* cho phép người dùng xem lại kết quả của từng phiên xử lý, bao gồm danh sách biển số nhận dạng được, các xe bị từ chối kèm lý do và ảnh crop làm minh chứng. *Xem lịch sử nhận dạng* cung cấp danh sách các phiên xử lý đã thực hiện theo tài khoản đăng nhập, giúp người dùng tra cứu lại kết quả của các video hoặc trích đoạn đã xử lý trước đó.

4.1.2 Thiết kế kiến trúc

Lựa chọn kiến trúc phần mềm Hệ thống áp dụng kiến trúc **ba lớp** (Three-tier Architecture) kết hợp với mô hình Client–Server. Kiến trúc này phân tách ứng dụng thành ba tầng độc lập: tầng trình bày chịu trách nhiệm hiển thị giao diện và tương tác với người dùng, tầng xử lý nghiệp vụ thực thi toàn bộ logic ứng dụng, và tầng dữ liệu quản lý việc lưu trữ và truy vấn dữ liệu bền vững. Mỗi tầng chỉ giao tiếp với tầng liền kề thông qua giao diện được định nghĩa rõ ràng, giúp các tầng có thể thay đổi hoặc mở rộng độc lập mà không ảnh hưởng lẫn nhau.

Kiến trúc này được lựa chọn vì hệ thống có đặc thù xử lý nặng ở phía máy chủ (do sử dụng pipeline AI đa tầng với nhiều mô hình học sâu hoạt động nối tiếp), trong khi giao diện người dùng cần phản hồi nhanh và không bị chặn trong quá trình chờ kết quả. Việc tách biệt rõ tầng nghiệp vụ cũng cho phép cải tiến hay thay thế các mô hình AI mà không cần thay đổi giao diện hay cơ sở dữ liệu.



Hình 4.2: Biểu đồ phụ thuộc gói

Biểu đồ phụ thuộc gói

Tầng trình bày (Presentation Tier) Tầng trình bày gồm ba package. Package *Authentication* chứa các màn hình xác thực người dùng, bao gồm màn hình đăng nhập và thành phần bảo vệ định tuyến, ngăn người dùng chưa xác thực truy cập các trang nghiệp vụ. Package *MainView* tổ chức toàn bộ giao diện sau đăng nhập, gồm trang tổng quan, màn hình tải video, màn hình xem kết quả và minh chứng, màn hình lịch sử và màn hình chọn trích đoạn từ nguồn video. Package *APIClient* đóng vai trò cầu nối duy nhất giữa tầng trình bày và tầng nghiệp vụ, cung cấp hai thành phần: client xử lý các yêu cầu REST đồng bộ và client nhận kết quả theo luồng thời gian thực từ server.

Tầng nghiệp vụ (Business Logic Tier) Tầng nghiệp vụ gồm hai package. Package *WebAPI* tiếp nhận và xử lý toàn bộ yêu cầu HTTP từ client, được tổ chức thành bốn router theo chức năng: *AuthAPI* quản lý đăng ký, đăng nhập và xác thực JWT; *RecognitionAPI* tiếp nhận video đầu vào, khởi động pipeline xử lý và phát kết quả về client qua SSE; *MonitorAPI* quản lý các phiên chọn trích đoạn từ camera trực tiếp hoặc video tải lên, đồng thời xử lý các sự kiện được người dùng đánh dấu;; *HistoryAPI* cung cấp dữ liệu lịch sử phiên nhận dạng theo tài khoản. Package *PipelineALPR* thực thi toàn bộ luồng xử lý AI, gồm năm sub-package hoạt động

theo chuỗi: FrameProcessing giải mã và tiền xử lý khung hình từ video đầu vào; VehicleDetection phát hiện phương tiện trong từng khung hình; VehicleTracking theo dõi từng phương tiện xuyên suốt các khung hình liên tiếp; PlateDetection phát hiện và trích xuất vùng biển số; PlateOCR nhận dạng ký tự biển số; ResultAggregation tổng hợp kết quả từ nhiều khung hình để đưa ra kết quả cuối cùng cho từng phương tiện.

Tầng dữ liệu (Data Tier) Tầng dữ liệu gồm hai package với trách nhiệm phân tách rõ ràng. Package Database lưu trữ toàn bộ dữ liệu có cấu trúc, gồm UserStore (thông tin tài khoản và phiên xác thực), RecognitionStore (kết quả các phiên nhận dạng và bản ghi từng phương tiện) và MonitorEventStore lưu thông tin các sự kiện do người dùng đánh dấu trên nguồn video, gồm nguồn dữ liệu, khoảng thời gian được chọn, trạng thái xử lý và kết quả nhận dạng. Package ObjectStorage lưu trữ dữ liệu nhị phân, cụ thể là EvidenceImageStore chứa ảnh crop biển số và ảnh minh chứng phương tiện; package Database chỉ lưu URL tham chiếu đến các tài nguyên này thay vì nhúng trực tiếp ảnh vào document.

4.2 Xây dựng ứng dụng

4.2.1 Công nghệ sử dụng

Hệ thống được phát triển bằng các công cụ, ngôn ngữ lập trình và thư viện trong Bảng 4.1.

Bảng 4.1: Danh sách thư viện và công cụ sử dụng

Mục đích	Công cụ/Thư viện	Phiên bản	Địa chỉ URL
IDE lập trình	Visual Studio Code	1.104.0	https://code.visualstudio.com/
Quản lý mã nguồn	Git	2.43.0	https://git-scm.com/
Đóng gói ứng dụng	Docker	28.5.1	https://www.docker.com/
Ngôn ngữ back-end	Python	3.10	https://www.python.org/
Runtime frontend	Node.js	20	https://nodejs.org/
Package manager	npm	11.6.3	https://www.npmjs.com/

CHƯƠNG 4. XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG

Mục đích	Công cụ/Thư viện	Phiên bản	Địa chỉ URL
Backend API	FastAPI	$\geq 0.111.0$	https://fastapi.tiangolo.com/
ASGI server	Uvicorn	$\geq 0.29.0$	https://www.uvicorn.org/
Học sâu	PyTorch	2.4.1	https://pytorch.org/
Xử lý ảnh	OpenCV Python	4.10.0.84	https://opencv.org/
Phát hiện đối tượng	Ultralytics YOLO	$\geq 8.0.0$	https://docs.ultralytics.com/
Theo dõi đối tượng	BoxMOT	19.0.0	https://github.com/mikel-brostrom/boxmot
Suy luận ONNX	ONNX Runtime	1.20.0	https://onnxruntime.ai/
Tính toán ma trận	NumPy	1.26.4	https://numpy.org/
Tính toán khoa học	SciPy	$\geq 1.11.0$	https://scipy.org/
Huấn luyện mô hình	Lightning	2.x	https://lightning.ai/
Xử lý ảnh phụ trợ	Pillow	$\geq 10.0.0$	https://python-pillow.org/
Đọc cấu hình	PyYAML	$\geq 6.0.1$	https://pyyaml.org/
Xác thực mật khẩu	bcrypt	$\geq 4.1.0$	https://github.com/pyca/bcrypt
JWT	PyJWT	$\geq 2.8.0$	https://pyjwt.readthedocs.io/
Cơ sở dữ liệu	MongoDB	7	https://www.mongodb.com/
Driver mongoDB	Motor	$\geq 3.3.0$	https://motor.readthedocs.io/

Mục đích	Công cụ/Thư viện	Phiên bản	Địa chỉ URL
Lưu trữ ảnh	Supabase	$\geq 2.5.0$	https://supabase.com/
Frontend framework	React	18.3.1	https://react.dev/
Điều hướng frontend	React Router DOM	7.17.0	https://reactrouter.com/
Build frontend	Vite	5.4.21	https://vite.dev/
Thiết kế giao diện	Tailwind CSS	3.4.19	https://tailwindcss.com/
Streaming video	MediaMTX	v1.19.1	https://github.com/bluenviron/mediamtx
Xử lý video	FFmpeg	6.1.1	https://ffmpeg.org/
Kiểm thử	pytest	–	https://docs.pytest.org/

4.2.2 Frontend

Frontend của hệ thống là ứng dụng web một trang được xây dựng bằng React và Vite. Giao diện không thực hiện suy luận mô hình trực tiếp mà đóng vai trò tiếp nhận đầu vào từ người dùng, gửi yêu cầu tới backend, nhận tiến độ xử lý qua cơ chế streaming và hiển thị kết quả nhận dạng theo từng phương tiện hoặc từng sự kiện.

Ứng dụng được tổ chức theo hai chế độ chính. Chế độ thứ nhất xử lý toàn bộ một video được tải lên, phù hợp với nhu cầu đánh giá kết quả nhận dạng trên một tệp video hoàn chỉnh. Chế độ thứ hai cho phép người dùng chọn một trích đoạn cần xử lý từ nguồn camera trực tiếp hoặc từ video đã tải lên. Người dùng chuyển đổi giữa hai chế độ này thông qua thành phần điều hướng trên thanh tiêu đề.

Thành phần	Vai trò
Quản lý xác thực	Quản lý trạng thái đăng nhập, gọi các API xác thực và tự động gắn token bảo mật cho các yêu cầu ghi dữ liệu.
Màn hình làm việc chính	Điều phối trạng thái chính: file video, tiến độ xử lý, danh sách phương tiện hợp lệ và danh sách kết quả bị loại.
Bảng điều khiển nguồn	Cho phép người dùng chọn file video và các tùy chọn xử lý trước khi gửi yêu cầu lên server.
Khung hiển thị video	Hiển thị video gốc hoặc khung hình đã chú thích được server gửi về trong quá trình xử lý.
Bảng kết quả nhận dạng	Hiển thị kết quả theo từng phương tiện, gồm biểu số tổng hợp, độ tin cậy, ảnh minh chứng và các khung hình trong bộ đệm theo dõi.
Màn hình lịch sử	Truy vấn và hiển thị danh sách các phiên xử lý đã lưu và kết quả chi tiết của từng phiên.
Màn hình chọn trích đoạn	Quản lý các phiên chọn trích đoạn từ nguồn camera trực tiếp hoặc video tải lên, tiếp nhận lệnh đánh dấu sự kiện và hiển thị kết quả nhận dạng theo luồng.

Bảng 4.2: Các thành phần giao diện chính

Trong chế độ xử lý toàn bộ video, người dùng chọn file tại bảng điều khiển nguồn. Sau khi gửi yêu cầu, hệ thống nhận về một mã định danh công việc và mở kết nối streaming để nhận các sự kiện: tiến độ theo frame, khung hình đang xử lý, kết quả từng phương tiện và trạng thái hoàn thành. Dữ liệu nhận được được cập nhật vào trạng thái của màn hình chính, nhờ vậy giao diện hiển thị tiến độ và kết quả mà không cần tải lại trang.

Trong chế độ chọn trích đoạn, người dùng trước hết chọn nguồn dữ liệu, có thể là camera trực tiếp hoặc video tải lên. Khi người dùng đánh dấu một khoảng thời gian cần xử lý, frontend gửi thông tin phiên, loại nguồn và mốc thời gian đã chọn tới server. Backend sau đó trích xuất các khung hình thuộc khoảng thời gian này, chạy pipeline nhận dạng biểu số và đẩy tiến độ cùng kết quả về frontend theo cơ chế streaming. Cách tổ chức này giúp thao tác chọn đoạn trên giao diện diễn ra nhanh, trong khi phần xử lý AI được thực hiện bất đồng bộ ở phía server.

4.2.3 Backend

Backend được xây dựng bằng FastAPI với một điểm khởi động duy nhất chịu trách nhiệm định nghĩa route, kiểm tra đầu vào, quản lý hàng đợi streaming và điều phối các công việc xử lý. Các phần tính toán nặng được tách riêng thành module lõi gồm nạp mô hình, phát hiện phương tiện, phát hiện biểu số, theo dõi đối tượng,

nhận dạng ký tự, chấm điểm chất lượng và tổng hợp kết quả.

Khi ứng dụng khởi động, các mô hình học sâu nặng (như YOLO, OCR) được nạp một lần duy nhất dưới dạng không trạng thái (stateless) để dùng chung, kết nối cơ sở dữ liệu được khởi tạo và tác vụ dọn dẹp các phiên chọn trích đoạn tạm thời được kích hoạt. Trong khi đó, các thành phần có trạng thái (stateful) như bộ theo dõi phương tiện (BoT-SORT) sẽ được khởi tạo độc lập cho từng phiên xử lý (per-session). Cách tổ chức này vừa giúp tiết kiệm bộ nhớ VRAM do không phải nhân bản các mô hình lớn, vừa đảm bảo dữ liệu theo dõi (bộ lọc Kalman, định danh track) của các video xử lý đồng thời không bị xung đột, đồng thời giải phóng tài nguyên an toàn khi phiên kết thúc.

Nhóm API	Chức năng
Xác thực	Tạo tài khoản, đăng nhập, đăng xuất, kiểm tra phiên người dùng và cấp token bảo mật cho các yêu cầu ghi dữ liệu.
Xử lý video tải lên	Tiếp nhận video, tạo công việc xử lý bất đồng bộ, phát tiến độ và kết quả theo luồng thời gian thực, cung cấp khung hình preview và kết quả chi tiết của từng phương tiện.
Lịch sử nhận dạng	Liệt kê các phiên xử lý đã lưu, lấy thông tin tổng quan một phiên và danh sách kết quả nhận dạng; chỉ trả dữ liệu thuộc về người dùng hiện tại.
Chọn trích đoạn và sự kiện	Tạo và quản lý phiên chọn trích đoạn từ file tải lên hoặc nguồn camera trực tiếp, tiếp nhận lệnh đánh dấu sự kiện, xử lý đoạn video tương ứng ở backend, phát tiến độ và kết quả theo luồng, đồng thời cung cấp API tra cứu lại các sự kiện đã lưu.

Bảng 4.3: Các nhóm API chính của backend

Luồng xử lý video được thiết kế theo cơ chế bất đồng bộ. Backend kiểm tra định dạng, dung lượng và tính hợp lệ của file đầu vào, sau đó sinh mã định danh công việc, tạo hàng đợi kết quả và khởi chạy pipeline trong một luồng riêng. Để đảm bảo tính ổn định trên máy chủ GPU, hệ thống sử dụng cơ chế kiểm soát đồng thời (bằng Semaphore) nhằm giới hạn số lượng tác vụ nhận dạng chạy song song (ví dụ: tối đa 2 video cùng lúc để tránh lỗi tràn bộ nhớ VRAM), và trả về mã lỗi HTTP 429 nếu vượt quá ngưỡng tải. Trong quá trình xử lý, backend đẩy liên tục các bản tin gồm tiến độ theo frame, khung hình preview, kết quả từng phương tiện và trạng thái hoàn thành theo chuẩn SSE, nhờ đó giao diện có thể cập nhật gần thời gian thực mà không cần hỏi vòng lặp.

Về bảo mật, mật khẩu người dùng được băm bằng thuật toán bcrypt, phiên đăng nhập được lưu phía máy chủ và token xác thực được gửi về trình duyệt trong cookie bảo mật chỉ đọc qua HTTP. Các yêu cầu ghi dữ liệu trong luồng xử lý video chính yêu cầu thêm token chống giả mạo yêu cầu trong header. Cách triển khai này tách dữ liệu xác thực khỏi mã nguồn giao diện và tránh lưu token truy cập trong bộ nhớ trình duyệt.

Lớp lưu trữ được tách khỏi lớp xử lý nghiệp vụ. Cơ sở dữ liệu lưu thông tin người dùng, phiên xử lý, kết quả nhận dạng và sự kiện được đánh dấu. Object storage lưu ảnh minh chứng để tránh lưu dữ liệu ảnh trực tiếp trong document. Nhờ cách tách này, backend API giữ vai trò điều phối, còn dữ liệu lớn và metadata được lưu ở các thành phần phù hợp.

4.2.4 Thiết kế cơ sở dữ liệu

Hệ thống sử dụng MongoDB làm cơ sở dữ liệu chính và một dịch vụ object storage tương thích S3 làm kho lưu trữ ảnh minh chứng. MongoDB lưu toàn bộ dữ liệu có cấu trúc gồm tài khoản người dùng, phiên đăng nhập, phiên xử lý video, kết quả nhận dạng và các sự kiện được đánh dấu trong chế độ chọn trích đoạn. Ảnh crop phương tiện, ảnh crop biển số và các khung hình minh chứng được lưu trên object storage; trong MongoDB chỉ lưu URL trỏ tới các đối tượng này.

Thiết kế này bám theo cách dữ liệu được sinh ra trong pipeline: một phiên xử lý có thể sinh nhiều phương tiện, mỗi phương tiện có một biển số cuối cùng và nhiều crop theo thời gian. Nếu lưu ảnh nhị phân trực tiếp trong document, kích thước tăng nhanh và khó mở rộng. Vì vậy hệ thống tách metadata khỏi ảnh: cơ sở dữ liệu giữ khóa truy vấn, kết quả OCR và các URL; object storage giữ dữ liệu ảnh.

Các collection chính Bảng 4.4 mô tả ánh xạ giữa các thực thể nghiệp vụ và collection trong MongoDB.

Bảng 4.4: Các collection và document trong MongoDB

Thực thể	Collection	Mô tả
Tài khoản người dùng	users	Lưu thông tin đăng ký, email duy nhất, mật khẩu đã băm và trạng thái tài khoản.
Phiên đăng nhập	auth_sessions	Lưu phiên đăng nhập phía máy chủ; tham chiếu đến tài khoản người dùng và hỗ trợ thu hồi phiên.
Phiên nhận dạng	recognition_sessions	Lưu metadata của một lượt xử lý video: tên file nguồn, trạng thái, số frame và chế độ xử lý.
Kết quả nhận dạng	recognition_records	Lưu kết quả cuối cùng của từng phương tiện: biển số tổng hợp, độ tin cậy, lớp xe và URL ảnh minh chứng. Mỗi record nhúng thêm danh sách crop biển số theo thời gian phục vụ màn hình xem minh chứng.
Sự kiện video	events	Lưu một cửa sổ thời gian được người dùng đánh dấu trên nguồn video, gồm loại nguồn, khoảng thời gian, trạng thái xử lý và danh sách phương tiện phát hiện được nhúng trực tiếp trong document.
Ảnh minh chứng	(Object Storage)	Không phải collection MongoDB. File ảnh lưu trên object storage; MongoDB chỉ lưu URL tham chiếu trong các trường tương ứng của kết quả nhận dạng và sự kiện.

Thiết kế chỉ mục Bảng 4.5 liệt kê các chỉ mục chính được tạo để phục vụ các truy vấn thường gặp của ứng dụng.

Bảng 4.5: Các chỉ mục MongoDB chính

Collection	Chỉ mục	Mục đích
users	email (duy nhất); created_at giảm dần	Đảm bảo email không trùng và tăng tốc đăng nhập.
auth_sessions	session_id (duy nhất); user_id; expires_at	Kiểm tra và truy vết phiên đăng nhập theo người dùng.
recognition_sessions	session_id (duy nhất); (user_id, created_at); status	Lấy phiên theo mã, liệt kê lịch sử gần nhất và lọc theo trạng thái.
recognition_records	session_id; (session_id, track_id) duy nhất; plate_text; vehicle_class	Lấy kết quả theo phiên, tránh lưu trùng track và hỗ trợ tìm kiếm biển số.
events	event_id (duy nhất); session_id; marked_at giảm dần; status	Lấy chi tiết sự kiện, liệt kê theo phiên và theo thời gian đánh dấu.

4.3 Triển khai

Ứng dụng được triển khai theo mô hình tách riêng frontend, backend xử lý AI và các dịch vụ lưu trữ. Frontend được triển khai trên Vercel, backend được đóng gói bằng Docker và chạy trên RunPod GPU. Cơ sở dữ liệu và lưu trữ ảnh kết quả sử dụng các dịch vụ bên ngoài để giảm tải cho server xử lý chính.

Thành phần	Cấu hình triển khai
Frontend	React/Vite, triển khai trên Vercel
Backend API	FastAPI, chạy trên cổng 8000
Server xử lý AI	RunPod GPU, NVIDIA RTX 3090
Môi trường GPU	PyTorch 2.4.1, CUDA 12.1, cuDNN 9
Streaming video	MediaMTX, sử dụng WebRTC/RTSP
Cơ sở dữ liệu	MongoDB Atlas
Lưu trữ ảnh kết quả	Supabase Storage
Giới hạn dung lượng upload	512 MB

Bảng 4.6: Cấu hình triển khai ứng dụng

Trong môi trường thử nghiệm cục bộ, hệ thống được chạy bằng Docker Compose gồm bốn dịch vụ chính: backend API, frontend web, MediaMTX và MongoDB. Backend mở cổng 8000, frontend mở cổng 3000, MongoDB mở cổng 27017, MediaMTX sử dụng các cổng 8554, 8889, 8189/udp và 9997. Cấu hình này phục vụ kiểm thử chức năng đăng nhập, tải video, xử lý nhận dạng và xem kết quả

trực tiếp.

Trong môi trường triển khai thử nghiệm trên server GPU, backend và MediaMTX được đóng gói trong cùng một Docker image. Backend đảm nhiệm các bước phát hiện phương tiện, phát hiện biển số, tracking, OCR và trả kết quả qua API. MediaMTX phục vụ luồng video trực tiếp, hỗ trợ hiển thị nguồn camera trong chế độ chọn trích đoạn trên giao diện web. Các mô hình như detector phương tiện, detector biển số, OCR và ReID được đặt trên network volume của RunPod.

CHƯƠNG 5. ĐÁNH GIÁ THỰC NGHIỆM

5.1 Môi trường và tiêu chí đánh giá

Chương này đánh giá các mô hình thành phần được dùng trong pipeline nhận dạng biển số trên video. Các kết quả được lấy từ hai nguồn: kết quả công bố của mô hình phát hiện phương tiện trong công trình của Che et al. [2], và các artifact huấn luyện, đánh giá hiện có trong mã nguồn đồ án.

Bảng 5.1: Môi trường đánh giá

Thành phần	Môi trường đánh giá
Phát hiện phương tiện	Số liệu lấy từ paper gốc, đánh giá trên GPU RTX A5000.
Phát hiện biển số, Quality Router, OCR	Python 3.10, PyTorch 2.6.0, CUDA 12.4, NVIDIA GeForce RTX 4050

Với các mô hình phát hiện đối tượng, đồ án sử dụng bốn chỉ số chính: Precision, Recall, mAP@0.5 và mAP@0.5:0.95. Precision đo tỷ lệ dự đoán đúng trong số các phát hiện được mô hình trả về, còn Recall đo tỷ lệ đối tượng thật được phát hiện:

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}$$

mAP@0.5 là mean Average Precision tại ngưỡng IoU 0.5. mAP@0.5:0.95 là trung bình mAP trên nhiều ngưỡng IoU từ 0.5 đến 0.95, do đó phản ánh chặt hơn chất lượng định vị hộp bao. Đối với mô hình phát hiện biển số OBB, IoU được tính trên hộp bao có hướng, phù hợp với biển số bị nghiêng trong khung hình.

Với mô hình OCR, tiêu chí chính là exact-match accuracy trên toàn chuỗi biển số. Một ảnh chỉ được tính đúng khi toàn bộ chuỗi ký tự sau khi decode trùng hoàn toàn với nhãn, bao gồm cả ký tự phân tách [SEP] đối với biển hai dòng. Ngoài ra, đồ án ghi nhận thêm layout accuracy để đánh giá khả năng phân biệt biển một dòng và hai dòng.

Với mô hình phân loại chất lượng biển số, tiêu chí chính là top-1 accuracy trên tập validation. Ngoài ra, đồ án quan sát thêm ma trận nhầm lẫn chuẩn hóa để đánh giá mức độ an toàn của bộ định tuyến, đặc biệt là khả năng tránh đẩy nhầm các crop còn đọc được sang nhánh không đọc.

5.2 Kết quả các mô hình thành phần

5.2.1 Mô hình phát hiện phương tiện

Trong pipeline triển khai, phát hiện phương tiện là bước đầu tiên nhằm giới hạn vùng tìm kiếm cho biển số. Các lớp phương tiện được giữ lại trong hệ thống gồm class ID 1, 6, 7, 8, 9 và 10, tương ứng xe máy, xe con, xe tải, xe tải van, xe buýt và xe ba gác chở hàng.

Paper gốc báo cáo kết quả cho giai đoạn phát hiện phương tiện và biển số với mô hình YOLOv5m, đầu vào 1280×720 . Bảng 5.2 trình bày lại các số liệu được dùng làm căn cứ cho mô hình phát hiện phương tiện kế thừa trong đồ án.

Bảng 5.2: Kết quả mô hình phát hiện phương tiện kế thừa từ Che et al. [2]

Kiến trúc	Kích thước đầu vào	Precision	Recall	mAP@0.5	Thời gian suy luận
YOLOv5m	1280×720	0.968	0.959	0.968	12.4 ms

Các chỉ số trên cho thấy mô hình phát hiện phương tiện có độ bao phủ tốt, Recall đạt 0.959, phù hợp với vai trò tăng đầu của pipeline. Trong bài toán video, lỗi bỏ sót phương tiện ở bước này sẽ làm mất toàn bộ cơ hội phát hiện biển số ở các bước sau, vì vậy Recall cao quan trọng hơn việc chỉ tối ưu Precision. Thời gian suy luận 12.4 ms trên RTX A5000 cũng cho thấy mô hình đủ nhanh để làm detector đầu vào cho luồng xử lý nhiều khung hình.

5.2.2 Mô hình phát hiện biển số

Mô hình phát hiện biển số được huấn luyện theo bài toán OBB với hai lớp trong file `data.yaml`: BSD và BSV. Việc tách hai lớp này giúp mô hình học riêng biển số dạng dài và dạng vuông/hai dòng. Khác với detector hộp ngang, YOLOv8-OBB trả về vùng biển số có góc xoay, thuận lợi hơn cho bước warp/crop trước OCR.

Bảng 5.3: Kết quả validation của mô hình phát hiện biển số YOLOv8-OBB

Mô hình	Epoch	Precision	Recall	mAP@0.5	mAP@0.5:0.95
YOLOv8-OBB	50	0.96776	0.94489	0.98292	0.95015

Kết quả cho thấy detector biển số đạt mAP@0.5 bằng 0.98292 và mAP@0.5:0.95 bằng 0.95015 trên tập validation. Khoảng cách nhỏ giữa hai chỉ số này cho thấy mô hình không chỉ phát hiện đúng vị trí tương đối của biển số, mà còn định vị khá sát hình học biển số. Đây là điểm quan trọng đối với OCR, vì crop lệch hoặc chứa nhiều nền thừa thường làm giảm độ chính xác nhận dạng ký tự, đặc biệt với biển số nhỏ trong video.

5.2.3 Kết quả huấn luyện mô hình Quality Router

Mô hình Quality Router được huấn luyện như một bộ phân loại ảnh crop biển số. Giai đoạn đầu sử dụng dữ liệu LPLCv2 để học khái niệm độ đọc được tổng quát của biển số, gồm bốn mức `perfect`, `good`, `poor` và `illegible`. Bên cạnh bài toán bốn lớp, đồ án cũng huấn luyện một biến thể nhị phân theo hướng phù hợp/không phù hợp với OCR trực tiếp. Sau đó, mô hình được fine-tune trên tập crop biển số Việt Nam để thích nghi với miền dữ liệu của pipeline.

Bảng 5.4: Kết quả validation của mô hình Quality Router

Thiết lập	Epoch tốt nhất	Top-1 accuracy	Val loss
LPLCv2 bốn mức chất lượng	35	85.287%	0.34785
LPLCv2 nhị phân phù hợp/không phù hợp	46	95.603%	0.10964
Fine-tune trên crop biển số Việt Nam	35	84.705%	0.38505

Kết quả cho thấy khi giữ nguyên bốn mức chất lượng, ranh giới giữa các lớp gần nhau như `perfect`, `good` và `poor` vẫn còn gây nhầm lẫn. Tuy nhiên, khi gom về bài toán nhị phân phù hợp/không phù hợp, độ chính xác tăng lên 95.603%. Điều này phù hợp với vai trò thực tế của Quality Router trong pipeline: thay vì yêu cầu phân biệt thật chi tiết từng mức chất lượng, bộ định tuyến chủ yếu cần quyết định crop nào đủ ổn định để OCR trực tiếp và crop nào nên được giữ lại cho xử lý theo track.



Hình 5.1: Ma trận nhầm lẫn chuẩn hóa của mô hình Quality Router sau fine-tune

Hình 5.1 cho thấy số lượng mẫu `perfect`, `good` và `poor` bị nhận nhầm thành

`illegible` là rất nhỏ. Cụ thể, hai lớp `perfect` và `good` hầu như không bị đẩy sang `illegible`, còn lớp `poor` chỉ có khoảng 2% bị nhầm theo hướng này. Đây là đặc tính quan trọng đối với hệ thống video, vì lỗi nghiêm trọng nhất của router là loại bỏ nhầm một crop vẫn còn tiềm năng nhận dạng.

5.2.4 Mô hình OCR

Mô hình nhận ảnh RGB kích thước 48×96 , sử dụng `d_model=256`, `backbone_ch=256`, STN, positional encoding hai chiều và các head CTC theo bố cục. Quá trình huấn luyện dùng AdamW với learning rate 3×10^{-4} , weight decay 10^{-4} , batch size 64 và cosine scheduler. Tập validation sau lọc gồm 5.527 ảnh crop biển số.

Bảng 5.5: Kết quả validation của checkpoint `SmallLPR_Line_CTC_9501`

Epoch	Exact Acc	Global Acc	Layout Acc	Val Loss	Checkpoint
44	0.95006	0.93233	0.99186	0.20710	<code>val_acc=0.9501</code>

Exact-match accuracy đạt 95.01%, nghĩa là khoảng 95 trên 100 ảnh validation được nhận dạng đúng toàn bộ chuỗi biển số. Đây là tiêu chí nghiêm ngặt hơn so với accuracy theo ký tự, vì chỉ cần sai một ký tự, thiếu dấu gạch, thiếu dấu chấm hoặc sai vị trí `[SEP]` thì mẫu được tính là sai. Layout accuracy đạt 99.19%, cho thấy mô hình phân biệt ổn định giữa biển một dòng và hai dòng. Kết quả này phù hợp với yêu cầu của pipeline: OCR một khung hình đã có độ chính xác cao, sau đó kết quả còn được kiểm tra định dạng và tổng hợp thêm qua nhiều khung hình để giảm lỗi do nhòe, rung và che khuất cục bộ.

5.2.5 Ablation study mô hình OCR

Để đánh giá ảnh hưởng của từng thành phần trong mô hình OCR đề xuất, đồ án thực hiện một chuỗi thí nghiệm ablation theo hướng tăng dần các module. Tất cả các mô hình được huấn luyện từ đầu trên cùng tập dữ liệu, cùng seed và cùng cấu hình huấn luyện. Chỉ số đánh giá là exact-match accuracy trên tập validation, tức một mẫu chỉ được tính đúng khi toàn bộ chuỗi ký tự dự đoán trùng hoàn toàn với nhãn.

Cách thiết kế thí nghiệm này tương tự hướng phân tích trong LPRNet, nơi tác giả tách riêng ảnh hưởng của data augmentation, STN alignment, beam search và hậu xử lý [6]. Trong đồ án này, các thành phần được chọn để ablation bám sát bài toán biển số Việt Nam hơn, gồm tăng cường dữ liệu, căn chỉnh STN, positional encoding hai chiều, các nhánh CTC theo layout và vertical prior cho biển hai dòng.

Bảng 5.6: Kết quả ablation của mô hình OCR

Run	Aug.	STN	2D PE	Layout heads	Prior đọc	Exact Acc
A0						87.53%
A1	✓					90.12%
A2	✓	✓				94.59%
A5	✓	✓	✓	✓	✓	95.01%

Kết quả trong Bảng 5.6 cho thấy hai bước cải thiện lớn nhất đến từ tăng cường dữ liệu và STN alignment. Khi chỉ thêm data augmentation, accuracy tăng từ 87.53% lên 90.12%. Khi bổ sung STN, accuracy tiếp tục tăng mạnh lên 94.59%, cho thấy việc căn chỉnh hình học có tác động rõ rệt đối với ảnh crop biển số từ video. Mô hình đầy đủ A5 đạt 95.01%, cao hơn A2 thêm 0.42 điểm phần trăm nhờ giữ đặc trưng hai chiều, tách head theo layout và bổ sung prior đọc cho biển hai dòng. Mức tăng này nhỏ hơn nhưng quan trọng, vì các thành phần này trực tiếp xử lý lỗi bố cục, thứ thường không xuất hiện rõ nếu chỉ đánh giá trên biển một dòng.

Ngoài chuỗi ablation trên tập OCR đầy đủ, đồ án cũng so sánh LPRNet gốc với mô hình `SmallLPR-Line-CTC` trên bộ dữ liệu chỉ gồm chữ và số. Thiết lập này loại bỏ ảnh hưởng của các ký tự phân tách và token bố cục, qua đó tập trung hơn vào năng lực nhận dạng chuỗi ký tự chính.

Bảng 5.7: So sánh OCR trên tập dữ liệu chỉ gồm chữ và số

Mô hình	Checkpoint tốt nhất	Exact Acc
LPRNet	<code>lprnet-epoch=045-val-acc=0.9272.ckpt</code>	92.72%
<code>SmallLPR-Line-CTC</code>	<code>small_lpr_line_ctc-epoch=040-val_acc=0.9633.ckpt</code>	96.33%

Kết quả này cho thấy mô hình đề xuất vẫn giữ lợi thế so với LPRNet ngay cả khi bài toán được đơn giản hóa về chuỗi chữ-số, với mức tăng 3.61 điểm phần trăm. Như vậy, cải tiến không chỉ đến từ việc xử lý token bố cục, mà còn từ backbone, cơ chế căn chỉnh và cách giữ thông tin không gian trong quá trình nhận dạng.

5.3 Đánh giá pipeline tổng thể

Sau khi đánh giá riêng từng mô hình thành phần, đồ án tiếp tục kiểm thử pipeline ALPR hoàn chỉnh trên các video thực tế. Mục tiêu của phần này là đánh giá khả năng phối hợp giữa các bước phát hiện phương tiện, phát hiện biển số, theo dõi đối tượng, OCR và tổng hợp kết quả đa khung hình. Khác với đánh giá từng mô hình độc lập, kết quả pipeline tổng thể phản ánh trực tiếp chất lượng đầu ra mà người dùng nhận được sau khi xử lý video.

Trong phần đánh giá này, một biển số được xem là nhận dạng đúng khi chuỗi ký tự chữ cái và chữ số trong kết quả dự đoán trùng khớp với nhãn thực tế. Các ký tự định dạng như khoảng trắng, dấu chấm và dấu gạch nối không được đưa vào so sánh. Cách đánh giá này phù hợp với mục tiêu nhận dạng định danh phương tiện, vì cùng một biển số có thể được hiển thị theo nhiều cách khác nhau trên giao diện.

5.3.1 Các kịch bản thử nghiệm

Các video thử nghiệm được chia thành ba nhóm kịch bản chính. Nhóm thứ nhất là kịch bản ban đêm, gồm các video có ánh sáng yếu, độ tương phản thấp và biển số thường chỉ rõ trong một số ít khung hình. Nhóm này dùng để kiểm tra khả năng khai thác thông tin đa khung hình của pipeline khi từng ảnh đơn lẻ không phải lúc nào cũng đủ tốt cho OCR.

Nhóm thứ hai là kịch bản ban đêm kết hợp ánh sáng chói. Các video trong nhóm này có nhiều nguồn sáng mạnh như đèn đường, đèn pha hoặc phản xạ từ thân xe. Một số video đồng thời có mật độ phương tiện cao, khiến các xe đi sát nhau và dễ gây nhầm lẫn trong bước liên kết track. Đây là kịch bản khó nhất vì lỗi có thể xuất hiện đồng thời ở nhiều tầng: detector có thể bỏ sót biển số nhỏ, OCR bị ảnh hưởng bởi lóa sáng, còn tracker có thể bị trộn định danh khi các phương tiện quá gần nhau.

Nhóm thứ ba là kịch bản điều kiện lý tưởng. Các video trong nhóm này có ánh sáng ổn định hơn, biển số rõ hơn và ít nhiễu hơn so với hai nhóm còn lại. Kịch bản này được dùng để kiểm tra giới hạn hoạt động của pipeline trong điều kiện thuận lợi, đồng thời quan sát các lỗi còn tồn tại khi chất lượng ảnh đầu vào không còn là nguyên nhân chính.

Bảng 5.8: Kết quả đánh giá pipeline tổng thể theo ba kịch bản thử nghiệm

Kịch bản	Số biển quan sát	Nhận dạng đúng	Trộn track
Ban đêm	28	24	Có
Đêm + ánh sáng chói	37	33	Có
Điều kiện lý tưởng	23	22	Có

Trong bảng trên, *Visible plates* là số biển số có thể quan sát được trong video và được đưa vào đánh giá. *OCR exacts* là số biển số được pipeline nhận dạng đúng hoàn toàn theo chuỗi chữ cái và chữ số. Trường *Trộn track* cho biết trong kịch bản đó có xuất hiện hiện tượng trộn track hoặc nhảy định danh giữa các phương tiện hay không.

5.3.2 Kết quả thực nghiệm

Ở kịch bản ban đêm, pipeline đạt 24/28 biển số đúng. Các lỗi còn lại chủ yếu đến từ OCR nhằm ký tự khi biển số bị tối, mờ hoặc chỉ xuất hiện rõ trong một số ít khung hình. Ví dụ, biển số 50H-53515 bị nhận dạng thành 50H-935.15, cho thấy hệ thống nhầm chữ số ở phần giữa chuỗi. Một trường hợp khác là 66-LA-02749 bị nhận dạng thành 66A-027.49, trong đó ký tự chữ cái bị thiếu hoặc bị gộp sai. Ngoài ra, có trường hợp chuỗi cuối không được nhận dạng đầy đủ, chẳng hạn 93-L1-34477 chỉ được trả về một phần dưới dạng 93-L1 344.???. Nhìn chung, nhóm ban đêm cho thấy pipeline vẫn giữ được độ ổn định tương đối nhờ cơ chế tổng hợp nhiều quan sát của cùng một phương tiện.

Ở kịch bản đêm kết hợp ánh sáng chói, pipeline đạt 33/37 biển số đúng. Đây là nhóm có mức nhiễu phức tạp nhất do biển số vừa chịu ảnh hưởng của ánh sáng yếu, vừa bị lóa bởi đèn đường, đèn pha hoặc phản xạ từ các phương tiện khác. Một số lỗi OCR xuất hiện khi ký tự bị lóa hoặc bị mất nét, ví dụ 30E-41101 bị nhận dạng thành 30 110I và 29T-8372 bị nhận dạng thành 29L-8372. Ngoài lỗi OCR, kịch bản này còn xuất hiện hiện tượng trộn track khi các phương tiện đi quá gần nhau, dẫn đến ảnh đại diện của track và kết quả OCR không còn khớp hoàn toàn. Đây là lỗi ở tầng truy vết, không chỉ riêng ở mô hình nhận dạng ký tự.

Ở kịch bản điều kiện lý tưởng, pipeline đạt 22/23 biển số đúng. Trong điều kiện ánh sáng tốt và biển số rõ hơn, hệ thống hoạt động ổn định hơn; một số dự đoán sai ở khung hình đơn lẻ vẫn có thể được sửa nhờ tổng hợp kết quả đa khung hình. Tuy nhiên, pipeline vẫn còn lỗi trong trường hợp ký tự bị nhầm lẫn có hệ thống. Ví dụ, biển xanh dương 51B 0493 bị tổng hợp thành 51F 0493, mặc dù trong track vẫn có một số khung hình nhận dạng đúng ký tự B. Điều này cho thấy bước bỏ phiếu cuối cùng vẫn có thể nghiêng về chuỗi sai nếu các khung hình sai có điểm tin cậy hoặc điểm chất lượng cao hơn.

Tổng cộng trên ba kịch bản, pipeline nhận dạng đúng 79/88 biển số quan sát được. Kết quả này cho thấy hướng tiếp cận theo track và tổng hợp đa khung hình giúp hệ thống hoạt động ổn định trong nhiều điều kiện video khác nhau, đặc biệt khi từng khung hình riêng lẻ có thể bị mờ, tối hoặc lóa. Tuy nhiên, các lỗi còn lại tập trung vào ba nguyên nhân chính: chất lượng crop biển số suy giảm do ánh sáng, nhầm lẫn ký tự trong OCR và trộn track khi nhiều phương tiện di chuyển quá gần nhau. Đây là các điểm cần tiếp tục cải thiện trong các phiên bản sau của hệ thống, đặc biệt ở bước truy vết phương tiện và cơ chế chọn khung hình đại diện cho mỗi track.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Đồ án đã xây dựng một hệ thống nhận diện biển số xe Việt Nam theo hướng xử lý video, trong đó kết quả cuối cùng không được quyết định từ một khung hình đơn lẻ mà được tổng hợp từ nhiều quan sát của cùng một phương tiện. Hệ thống kết hợp các khối phát hiện phương tiện, theo dõi đối tượng, phát hiện biển số bằng hộp bao có hướng, đánh giá chất lượng crop, OCR và tổng hợp kết quả theo track. Cách tổ chức này phù hợp với bản chất của bài toán ALPR trong môi trường thực tế: biển số thường nhỏ, thay đổi góc nhìn liên tục, dễ bị mờ do chuyển động, thiếu sáng hoặc lóa sáng, trong khi chuỗi video lại cung cấp thông tin dư thừa theo thời gian có thể khai thác để tăng độ ổn định nhận dạng.

Về mặt phương pháp, đóng góp chính của đồ án nằm ở việc chuyển đơn vị xử lý từ ảnh biển số độc lập sang track phương tiện. Bộ theo dõi giúp gom các crop biển số thuộc cùng một xe, từ đó cho phép hệ thống trì hoãn quyết định khi ảnh chưa đủ tốt và chỉ chốt kết quả sau khi đã có đủ bằng chứng. Thiết kế này kế thừa tinh thần khai thác thông tin dư thừa theo thời gian trong các nghiên cứu ALPR trên video [1], [2], nhưng được mở rộng thêm bằng cơ chế định tuyến chất lượng và bộ đệm track. Thay vì ép OCR đọc mọi crop, hệ thống phân biệt các ảnh có thể đọc trực tiếp, các ảnh nên đưa vào tổng hợp đa khung hình và các ảnh chỉ nên lưu làm bằng chứng. Nhờ đó, pipeline giảm phụ thuộc vào một khung hình may rủi và phản ánh tốt hơn cách con người quan sát biển số trong video.

Các kết quả thực nghiệm cho thấy từng thành phần chính của hệ thống đạt mức hiệu quả phù hợp với mục tiêu đặt ra. Mô hình phát hiện biển số YOLOv8-OBb đạt mAP@0.5 bằng 0,98292 và mAP@0.5:0.95 bằng 0,95015 trên tập validation, cho thấy khả năng định vị biển số tốt ngay cả khi cần xét hình học hộp bao có hướng. Mô hình OCR đạt exact-match accuracy 95,01% và layout accuracy 99,19%, đáp ứng yêu cầu nhận dạng toàn chuỗi đối với cả biển một dòng và hai dòng. Ở mức pipeline tổng thể, hệ thống nhận dạng đúng 79/88 biển số quan sát được trên ba nhóm kịch bản thử nghiệm, bao gồm ban đêm, ban đêm kết hợp ánh sáng chói và điều kiện lý tưởng. Kết quả này cho thấy hướng tiếp cận theo track có khả năng vận hành trên video thực tế, đặc biệt trong những trường hợp từng khung hình riêng lẻ không đủ ổn định cho OCR.

Bên cạnh kết quả đạt được, đồ án cũng chỉ ra các giới hạn quan trọng. Thứ nhất, lỗi vẫn xuất hiện khi crop biển số bị suy giảm mạnh bởi ánh sáng yếu, lóa sáng, mờ chuyển động hoặc độ phân giải thấp. Đây là nhóm lỗi phổ biến trong các nghiên

cứu gần đây về khôi phục và nhận dạng biển số chất lượng thấp, nơi yêu cầu không chỉ làm rõ ảnh mà còn phải bảo toàn nội dung bằng chứng của biển số [16]. Thứ hai, OCR vẫn có thể nhầm các ký tự có hình dạng gần nhau hoặc bị thiên lệch bởi một số dự đoán sai có điểm tin cậy cao. Thứ ba, tăng tracking còn gặp hiện tượng trộn track khi nhiều phương tiện đi quá gần nhau, dẫn đến ảnh evidence và kết quả OCR có thể không còn khớp hoàn toàn với cùng một phương tiện. Ngoài ra, tập thử nghiệm video thực tế trong đồ án vẫn còn giới hạn về quy mô, vùng miền, loại camera và điều kiện thời tiết, nên chưa đủ để kết luận đầy đủ về khả năng tổng quát hóa của hệ thống trên mọi bối cảnh giao thông.

Từ quá trình thực hiện, có thể rút ra rằng độ chính xác của một hệ thống ALPR thực tế không chỉ phụ thuộc vào một mô hình OCR mạnh. Chất lượng phát hiện, độ ổn định tracking, cách chọn frame, cách kiểm tra định dạng, cách tổng hợp kết quả và cách lưu bằng chứng đều ảnh hưởng trực tiếp đến đầu ra cuối cùng. Vì vậy, hướng tiếp cận pipeline đa tầng tuy phức tạp hơn so với nhận dạng ảnh đơn, nhưng phù hợp hơn với yêu cầu triển khai thực tế: hệ thống cần biết khi nào nên đọc ngay, khi nào nên chờ thêm bằng chứng và khi nào nên từ chối một kết quả không đủ tin cậy.

6.2 Hướng phát triển

Hướng phát triển trước tiên là cải thiện tăng tracking và liên kết biển số–phương tiện. Kết quả thực nghiệm cho thấy trộn track là một trong những nguyên nhân chính làm giảm chất lượng pipeline tổng thể, đặc biệt ở các cảnh đông phương tiện hoặc có che khuất ngắn. Các phiên bản tiếp theo có thể bổ sung đặc trưng ReID chuyên biệt cho phương tiện giao thông Việt Nam, kết hợp quỹ đạo chuyển động dài hơn, ràng buộc vị trí biển số trên thân xe và cơ chế kiểm tra nhất quán theo thời gian. Việc đánh giá tracker cũng nên được tách thành các chỉ số riêng như số lần nhảy định danh, số track bị gộp và tỷ lệ liên kết đúng giữa biển số và phương tiện. Khi tăng tracking được đo lường độc lập, hệ thống sẽ dễ xác định lỗi đến từ detector, tracker hay OCR hơn.

Hướng thứ hai là nâng cấp xử lý ảnh chất lượng thấp theo hướng đa khung hình. Thay vì chỉ chọn frame tốt nhất hoặc tăng cường từng crop độc lập, hệ thống có thể căn chỉnh nhiều crop biển số trong cùng một track bằng optical flow hoặc homography cục bộ, sau đó tổng hợp thông tin từ các khung hình lân cận. Các nghiên cứu mới về multi-frame license plate restoration cho thấy việc khai thác chuỗi khung hình có thể cải thiện đáng kể nhận dạng trong trường hợp ảnh đơn bị mờ, lóa hoặc độ phân giải thấp [16]. Tuy nhiên, với bài toán biển số, khôi phục ảnh cần được thiết kế thận trọng: mô hình không được tạo ra ký tự giả hoặc làm biến

dạng bằng chứng. Vì vậy, hướng phù hợp là kết hợp khôi phục đa khung hình với điểm tin cậy OCR, kiểm tra định dạng và lưu lại các crop gốc để phục vụ đối chiếu.

Hướng thứ ba là cải thiện mô hình nhận dạng chuỗi ký tự. Mô hình hiện tại đã đạt kết quả tốt với kiến trúc CTC nhẹ, nhưng các hướng nhận dạng hiện đại đang chuyển dần sang Transformer, mô hình thị giác-ngôn ngữ và các cơ chế nhận thức bố cục linh hoạt hơn [17]. Đối với biển số Việt Nam, hướng này có thể được khai thác để xử lý tốt hơn các trường hợp biển đặc biệt, biển hai dòng, ký tự bị dính hoặc ký tự bị mất nét cục bộ. Tuy nhiên, khi dùng mô hình có khả năng học ngữ cảnh mạnh, cần tránh để mô hình quá phụ thuộc vào cú pháp biển số đã thấy trong huấn luyện. Các nghiên cứu về nhận dạng biển số trong bối cảnh thay đổi cú pháp cho thấy Transformer có thể đạt kết quả cao trên định dạng quen thuộc nhưng suy giảm mạnh khi gặp cấu trúc mới [18]. Vì vậy, hướng phát triển nên kết hợp ràng buộc định dạng ở mức hậu xử lý có kiểm soát với huấn luyện nhận dạng đủ mở, nhằm vừa tận dụng luật biển số Việt Nam, vừa không làm mô hình “đoán” theo mẫu cũ khi ảnh đầu vào không đủ bằng chứng.

Hướng thứ tư là mở rộng dữ liệu và quy trình đánh giá. Các bộ dữ liệu ALPR quy mô lớn gần đây nhấn mạnh vai trò của đa dạng quốc gia, loại phương tiện, kiểu biển, điều kiện ánh sáng và chú thích hình học chi tiết [19]. Đối với phạm vi Việt Nam, hệ thống cần được đánh giá thêm trên nhiều tỉnh thành, nhiều loại camera, thời tiết mưa/sương, camera hành trình, camera cố định, góc nhìn cao/thấp và mật độ phương tiện khác nhau. Bên cạnh accuracy cuối cùng, cần bổ sung các đánh giá ablation để đo riêng tác động của tracking, quality routing, tiền xử lý ảnh, CTM và cơ chế bỏ phiếu. Một bộ benchmark nội bộ có nhãn track, nhãn biển số và nhãn chất lượng khung hình sẽ giúp quá trình cải tiến có cơ sở định lượng rõ hơn thay vì chỉ quan sát lỗi thủ công.

Hướng thứ năm là tối ưu triển khai và hoàn thiện sản phẩm. Pipeline hiện tại đã chứng minh được tính khả thi ở mức thực nghiệm, nhưng để vận hành ổn định trong môi trường thật cần tiếp tục tối ưu tốc độ, bộ nhớ và độ trễ. Các mô hình có thể được chuyển sang ONNX hoặc TensorRT, kết hợp quantization, pruning hoặc distillation để phục vụ thiết bị biên. Luồng xử lý cũng có thể được tổ chức bất đồng bộ hơn, tách rõ các bước đọc video, suy luận detector, OCR, lưu evidence và phát kết quả về giao diện. Về phía ứng dụng, cần bổ sung cơ chế giám sát lỗi, ghi log theo phiên, theo dõi drift dữ liệu, kiểm soát quyền truy cập evidence và vòng phản hồi người dùng để sửa nhãn sai. Khi các yếu tố này được hoàn thiện, hệ thống không chỉ là một pipeline nhận dạng, mà có thể trở thành một nền tảng ALPR có khả năng học tiếp từ dữ liệu thực tế và cải thiện dần sau mỗi lần triển khai.

TÀI LIỆU THAM KHẢO

- [1] R. Laroca, E. Severo, L. A. Zanlorensi, *et al.*, “A robust real-time automatic license plate recognition based on the yolo detector,” *2018 International Joint Conference on Neural Networks (IJCNN)*, pp. 1–10, 2018.
- [2] Q. H. Che, T. Do Thanh, and C. Truong Van, “Character time-series matching for robust license plate recognition,” in *2022 International Conference on Multimedia Analysis and Pattern Recognition (MAPR)*, 2022, pp. 1–6. DOI: 10.1109/MAPR56351.2022.9924897. [Online]. Available: <https://arxiv.org/abs/2307.11336>.
- [3] Ultralytics, *Ultralytics yolov8 docs - oriented bounding box (obb) datasets overview*, 2023. [Online]. Available: <https://docs.ultralytics.com/>.
- [4] N. Aharon, R. Orfaig, and B.-Z. Bobrovsky, “Bot-sort: Robust associations multi-pedestrian tracking,” *arXiv preprint arXiv:2206.14651*, 2022.
- [5] B. Shi, X. Bai, and C. Yao, “An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 39, no. 11, pp. 2298–2304, 2015.
- [6] S. Zherzdev and A. Gruzdev, “Lprnet: License plate recognition via deep neural networks,” *arXiv preprint arXiv:1806.10447*, 2018.
- [7] Y. Du, Z. Chen, C. Jia, *et al.*, “Svtr: Scene text recognition with a single visual model,” *arXiv preprint arXiv:2205.00159*, 2022.
- [8] M. Li, T. Lv, J. Chen, *et al.*, “Trocr: Transformer-based optical character recognition with pre-trained models,” *AAAI*, 2023.
- [9] D. Bautista and R. Atienza, “Scene text recognition with permuted autoregressive sequence models,” *European Conference on Computer Vision*, pp. 178–196, 2022.
- [10] JaidedAI, *Easyocr*, 2020. [Online]. Available: <https://github.com/JaidedAI/EasyOCR>.
- [11] PaddlePaddle, *Paddleocr*, 2020. [Online]. Available: <https://github.com/PaddlePaddle/PaddleOCR>.
- [12] L. Wojcik, E. A. F. Machoski, E. J. Nascimento, R. Laroca, and D. Menotti, “LPLCv2: An expanded dataset for fine-grained license plate legibility classification,” *arXiv preprint arXiv:2604.08741*, 2026. [Online]. Available: <https://arxiv.org/abs/2604.08741>.

- [13] M. Jaderberg, K. Simonyan, A. Zisserman, and K. Kavukcuoglu, “Spatial transformer networks,” in *Advances in Neural Information Processing Systems*, vol. 28, 2015. [Online]. Available: <https://arxiv.org/abs/1506.02025>.
- [14] M. Tan and Q. V. Le, “Mixconv: Mixed depthwise convolutional kernels,” in *British Machine Vision Conference (BMVC)*, 2019. [Online]. Available: <https://arxiv.org/abs/1907.09595>.
- [15] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “Cbam: Convolutional block attention module,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 3–19. [Online]. Available: https://openaccess.thecvf.com/content_ECCV_2018/html/Sanghyun_Woo_Convolutional_Block_Attention_ECCV_2018_paper.html.
- [16] K. Na, J. Oh, Y. Cho, *et al.*, “MF-LPR2: Multi-frame license plate image restoration and recognition using optical flow,” *Computer Vision and Image Understanding*, vol. 256, p. 104361, 2025. DOI: 10.1016/j.cviu.2025.104361. [Online]. Available: <https://doi.org/10.1016/j.cviu.2025.104361>.
- [17] N. AlDahoul, M. J. T. Tan, R. R. Tera, *et al.*, “Advancing vehicle plate recognition: Multitasking visual language models with vehiclepaligemma,” *arXiv preprint arXiv:2412.14197*, 2024. [Online]. Available: <https://arxiv.org/abs/2412.14197>.
- [18] F. Meyer, L. Guichard, D. Coquenat, G. Gravier, Y. Soullard, and B. Couasnon, “Relaxed syntax modeling in transformers for future-proof license plate recognition,” *arXiv preprint arXiv:2506.17051*, 2025. [Online]. Available: <https://arxiv.org/abs/2506.17051>.
- [19] S. Agrawal, “Global license plate dataset,” *arXiv preprint arXiv:2405.10949*, 2024. [Online]. Available: <https://arxiv.org/abs/2405.10949>.